

# Zápisky z pravděpodobnosti a statistiky FEL ČVUT

Přednášky Mgr. Matěj Novotný, Ph. D.

František Boháček

LS 2021, verze 200521

## Obsah

<b>1 Úvod, upozornění</b>	<b>3</b>
<b>2 Poděkování</b>	<b>3</b>
<b>3 Seznam klíčových pojmů</b>	<b>3</b>
<b>Přednáška 1: Základy pravděpodobnosti</b>	<b>4</b>
<b>Přednáška 2: Definice pravděpodobnosti</b>	<b>4</b>
<b>Přednáška 3: Pravděpodobnostní prostor</b>	<b>5</b>
<b>Přednáška 4: Princip inkluze a exkluze, nezávislost</b>	<b>6</b>
<b>Přednáška 5: Podmíněná pravděpodobnost, VoÚP</b>	<b>6</b>
<b>Přednáška 6: Bayesův vzorec a náhodné veličiny</b>	<b>7</b>
<b>Přednáška 7: Náhodné veličiny</b>	<b>8</b>
<b>Přednáška 8: Náhodné veličiny</b>	<b>9</b>
<b>Přednáška 9: Náhodné veličiny</b>	<b>11</b>
<b>Přednáška 10: Rozdělení náhodných veličin</b>	<b>14</b>
10.1 Alternativní rozdělení (nula-jedničkové, indikátor jevu) . . . . .	15
10.2 Binomické rozdělení . . . . .	16
10.3 Geometrické rozdělení . . . . .	16
10.4 Rovnoměrné rozdělení na intervalu . . . . .	16
<b>Přednáška 11: Rozdělení náhodných veličin</b>	<b>17</b>
11.1 Poissonovo rozdělení (rozdělení řídkých jevů) . . . . .	17

11.2 Exponenciální rozdělení . . . . .	17
11.3 Gaussovo (normální) rozdělení . . . . .	18
<b>Přednáška 12: Rozdělení náhodných veličin</b>	<b>20</b>
12.1 Paretovo rozdělení (někdy také 80:20 rozdělení) . . . . .	20
<b>Přednáška 13: Náhodné vektory</b>	<b>21</b>
<b>Přednáška 14: Příklady na náhodné vektory, jejich charakteristiky</b>	<b>23</b>
14.1 Charakteristiky náhodných vektorů . . . . .	24
<b>Přednáška 15: Náhodné vektory</b>	<b>26</b>
<b>Přednáška 16: Náhodné vektory</b>	<b>27</b>
<b>Přednáška 17: Limitní věty</b>	<b>29</b>
<b>Přednáška 18: Centrální limitní věta</b>	<b>31</b>
<b>Přednáška 19: Důkaz CLV</b>	<b>34</b>
<b>Přednáška 20: Konvergence CLV pro různá rozdělení, teorie odhadu</b>	<b>36</b>
<b>Přednáška 21: Výběrový rozptyl, metoda maximální věrohodnosti</b>	<b>38</b>
21.1 Metoda maximální věrohodnosti (Maximum likelihood method) . . . . .	39
<b>Přednáška 22: Příklad MMV pro <math>P_a()</math>, Odhady</b>	<b>41</b>
<b>Přednáška 23: Chí kvadrát, Studentovo rozdělení</b>	<b>44</b>
<b>Přednáška 24: Studentovo t-rozdělení, testování hypotéz</b>	<b>45</b>
24.1 Testování hypotéz . . . . .	47
<b>Přednáška 25: Statistické testy</b>	<b>49</b>
25.1 Testy normálního rozdělení . . . . .	49
25.2 Párový T-test . . . . .	50
<b>Přednáška 26: Statistické testy</b>	<b>52</b>
26.1 Dvouvýběrový T-test . . . . .	52
26.2 Test shodnosti rozptylů (norm. rozdělení) . . . . .	53
26.3 Test homogenity 2 binomických rozdělení . . . . .	54
<b>Přednáška 27: Chí kvadrát testy, testy dobré shody</b>	<b>55</b>
27.1 Test parametrů multinomického rozdělení . . . . .	56

## 1 Úvod, upozornění

Tento dokument obsahuje mé vlastní zápisky z přednášek z kurzu B0B01PST na ČVUT FEL (Letní semestr 2021). Neručím za žádné chyby, co se v dokumentu mohou objevit. Jakékoliv připomínky mi pošlejte na Discord **Rutherther#8497**.

V dokumentu nejsou všechny příklady z přednášek. Zvláště ne ty, pro které je potřeba nakreslit obrázek.

Dokument by měl obsahovat všechny probrané definice, tvrzení, věty, ale může se stát, že něco chybí. V takovém případě mi to můžete také nahlásit na můj Discord.

## 2 Poděkování

Chtěl bych poděkovat zejména panu doktorovi Matěji Novotnému za opravu spousty chyb nebo překlepů v těchto zápiscích. Dále také Martinu Mrázovi za doručení těchto chyb ke mně.

## 3 Seznam klíčových pojmů

- 3.1 Pravděpodobnostní prostor

Prostor elementárních jevů, množina všech jevů a pravděpodobnost. Elementární jev, jev. Příklady.

- 4.2 Nezávislost jevů

Nezávislost dvou jevů, nezávislost  $n$  jevů, po dvou nezávislé jevy. Příklady.

- 5.1 Podmíněná pravděpodobnost

Podmíněná pravděpodobnost vs. nezávislost. Příklady.

- 6.2 Náhodná veličina

7.1 Diskrétní náhodná veličina, 7.3 Spojitá náhodná veličina. 7.4 Distribuční funkce náhodné veličiny a její existence. Příklady.

- Charakteristiky náhodných veličiny

Střední hodnota diskrétní/spojité náhodné veličiny. Rozptyl náhodné veličiny, směrodatná odchylka.

- Příklady pravděpodobnostních rozdělení

Alternativní rozdělení, binomické rozdělení, rovnoměrné rozdělení na intervalu. Gaussovo (normální) rozdělení, normované normální rozdělení, Paretovo rozdělení. Jejich charakteristiky, příklady.

- Náhodné vektory

Náhodný vektor, sdružená distribuční funkce. Spojitě rozdělený n. vektor, diskrétně rozdělený n. vektor. Marginální rozdělení.

- Charakteristiky náhodných vektorů

Střední hodnota n. vektoru, kovariance veličin, korelace veličin. Varianční matice vektoru, korelační matice vektoru. Vztah kovariance a rozptylu.

- Nezávislost náhodných veličin

Nezávislost n náhodných veličin, souvislost s distribučními funkcemi. Nezávislost (spočetně) mnoha náhodných veličin.

- Náhodný výběr

Náhodný výběr, realizace náhodného výběru.

- Bodový odhad parametru

Výběrový průměr, výběrový rozptyl, výběrová směrodatná odchylka. Nestraný odhad parametru.

- Intervalový odhad

Intervalový odhad, spolehlivost odhadu.

- Testování hypotéz

Test nulové hypotézy proti alternativní, chyba 1. druhu, chyba 2. druhu, kritický obor. Jednovýběrový T-test.

## Přednáška 1: Základy pravděpodobnosti

17. 2. 2021

**Příklad.** Dva hráči hrají hru, u níž mají oba stejnou šanci na výhru. Hrají do té doby, než jeden z nich získá 5 výher. Přejde bouře, hra musí skončit za stavu 4:3. V jakém poměru by si měli rozdělit odměnu určenou tomu, kdo první vyhraje 5x.

Šance na výhru 1 ... a

Šance na výhru 2 ... b

## Přednáška 2: Definice pravděpodobnosti

18. 2. 2021

**Definice 2.1.** Sigma algebra

Mějme množinu  $\Omega$ . Množinu  $\mathcal{A} \subseteq 2^\Omega$  nazveme  $\sigma$ -algebrou, pokud:

- $\emptyset \in \mathcal{A}$
- $A \in \mathcal{A} \implies \overline{A} \in \mathcal{A}$
- $A_1, A_2, A_3, \dots \in \mathcal{A} \implies P(\cup_{n=1}^\infty A_n) \in \mathcal{A}$

**Definice 2.2.** Buďte  $\Omega$  neprázdná množina,  $\mathcal{A}$   $\sigma$ -algebra na  $\Omega$ .

Funkci  $P: \mathcal{A} \rightarrow [0, 1]$ , splňující:

1.  $P(A) \geq 0, A \in \mathcal{A}$
2. pro systém navzájem disjunktních množin  $A_1, A_2, A_3, \dots, A_n \in \mathcal{A}$  platí, že  $P(\cup_{n=1}^\infty A_n) = \sum_{n=1}^\infty P(A_n)$
3.  $P(\Omega) = 1$
4. ( $P(\emptyset) = 0$ ) lze vypustit, vyplývá z předchozích

nazveme pravděpodobností na  $\Omega$ .

**Příklad.** Hodíme kostkou

$\Omega = \{1, 2, 3, 4, 5, 6\}$  (množina elementárních jevů, každému prvku  $\Omega$  říkáme elementární jev)

$\mathcal{A} = 2^\Omega$  je množina jevů (např.  $\{2, 4, 6\}, \{1, 2\}, \{1\}$ )

$A \in \mathcal{A}, P(A) = \frac{|A|}{|\Omega|}$

**Přednáška 3: Pravděpodobnostní prostor**

24. 2. 2021

**Definice 3.1.** Pravděpodobnostní prostor

Mějme neprázdnou množinu  $\Omega$ ,  $\sigma$ -algebrou  $\mathcal{A}$  na množině  $\Omega$  a pravděpodobnost  $P: \mathcal{A} \rightarrow \mathbb{R}$ .

Uspořádanou trojici  $(\Omega, \mathcal{A}, P)$  nazýváme pravděpodobnostní prostor, množinu  $\Omega$  množina elementárních jevů a  $\mathcal{A}$  nazýváme množinou jevů, speciálně  $\emptyset$  je jev nemožný,  $\Omega$  je jev jistý.

**Věta 3.2.** Necht'  $(\Omega, \mathcal{A}, P)$  je pstní prostor, potom:

1.  $A \in \mathcal{A}: P(A) + P(\overline{A}) = 1$
2.  $A_1 \subseteq A_2 \subseteq A_3 \subseteq \dots, A_i \in \mathcal{A} \implies P(\cup_{n=1}^\infty A_n) = \lim_{n \rightarrow \infty} P(A_n)$

$$3. A_1 \supseteq A_2 \supseteq A_3 \supseteq \dots, A_i \in \mathcal{A} \implies P(\cap_{n=1}^{\infty} A_n) = \lim_{n \rightarrow \infty} P(A_n)$$

#### Přednáška 4: Princip inkluze a exkluze, nezávislost

25. 2. 2021

**Definice 4.1.** Princip inkluze a exkluze

Mějme jevy  $A_1, \dots, A_n$  na prostoru  $(\Omega, \mathcal{A}, P)$ .

Potom platí, že pravděpodobnost

$$\begin{aligned} P(\cup_{k=1}^n A_k) &= \sum_{k=1}^n P(A_k) \\ &\quad - \sum_{1 \leq i < k \leq n} P(A_i \cap A_k) \\ &\quad + \sum_{1 \leq i < k < j \leq n} P(A_i \cap A_k \cap A_j) \\ &\quad - \dots \\ &\quad + (-1)^{n-1} P(\cap_{k=1}^n A_k) \end{aligned}$$

**Definice 4.2.** Nezávislost jevů

Nechť  $A, B$  jsou jevy na  $(\Omega, \mathcal{A}, P)$ . Říkáme, že  $A, B$  jsou nezávislé, platí-li

$$P(A \cap B) = P(A) \cdot P(B)$$

**Tvrzení 4.3.** Tvrzení o nezávislých jevech

Nechť  $A, B$  jsou jevy na  $(\Omega, \mathcal{A}, P)$ .

Potom platí:

1.  $A \cap B = \emptyset \implies P(A) = 0 \vee P(B) = 0 \vee A, B$  jsou závislé.
2. Dvojice  $(\Omega, A), (\emptyset, A)$  jsou nezávislé  $\forall A \in \mathcal{A}$ .
3.  $A, B$  jsou nezávislé  $\implies A, \overline{B}$  nezávislé.
4.  $A, B$  nezávislé  $\implies \overline{A}, \overline{B}$  nezávislé.

#### Přednáška 5: Podmíněná pravděpodobnost, VoÚP

3. 3. 2021

**Definice 5.1.** Podmíněná pravděpodobnost

Nechť  $(\Omega, \mathcal{A}, P)$  je pstní prostor. Buďte  $A, B \in \mathcal{A}, P(B) > 0$ .

Podmíněnou pst jevu  $A$  za podmínky  $B$  značíme  $P(A|B)$  a definujeme

$$P(A|B) = \frac{P(A \cap B)}{P(B)}.$$

**Definice 5.2.** Úplný systém jevů

Buď  $(\Omega, \mathcal{A}, P)$  pstní prostor. Systém jevů  $A_1, A_2, A_3, \dots, A_i \in \mathcal{A}$  nazvu úplný systém jevů, pokud platí:

1.  $P(A_i \cap A_j) = 0$  pro  $i \neq j$
2.  $P(\cup_{i=1}^{\infty} A_i) = 1$ .

**Věta 5.3.** Věta o úplné pravděpodobnosti

Mějme  $B = \{B_1, B_2, B_3, \dots\}$ , úplný systém jevů na  $(\Omega, \mathcal{A}, P)$ . Nechť  $P(B_i) > 0$  pro každé  $i \in \mathbb{N}$ .

Potom pro každý jev  $A \in \mathcal{A}$  platí

$$P(A) = \sum_{i=1}^{\infty} P(A|B_i) \cdot P(B_i)$$

**Přednáška 6: Bayesův vzorec a náhodné veličiny**

4. 3. 2021

**Tvrzení 6.1.** Bayesův vzorec

Mějme  $B_1, B_2, \dots, B_n$ , jevy na  $(\Omega, \mathcal{A}, P)$  tvořící úplný systém jevů s nenulovou pstí  $P(B_i) > 0, i \in \mathbb{N}$ .

Potom každý jev  $A \in \mathcal{A} > 0$ , platí:

$$\forall i \in \mathbb{N} : P(B_i|A) = \frac{P(A|B_i) \cdot P(B_i)}{\sum_{j=1}^{\infty} P(A|B_j) \cdot P(B_j)}$$

**Definice 6.2.** Náhodná veličina

Mějme pstní prostor  $(\Omega, \mathcal{A}, P)$ . Reálnou funkci  $X : \Omega \rightarrow \mathbb{R}$  nazveme náhodnou veličinou, pokud pro každý interval  $I \in \mathbb{R}$  platí:  $X^{-1}(I) \in \mathcal{A}$  (podmínka měřitelnosti)

## Přednáška 7: Náhodné veličiny

10. 3. 2021

**Definice 7.1.** Diskrétní náhodná veličina

Náhodnou veličinu  $X$  nazveme diskrétní, nabývá-li nejvýše spočetně mnoha hodnot.

**Definice 7.2.** Pravděpodobnostní funkce

Funkce  $p_X : \mathbb{R} \rightarrow \mathbb{R}$ ,  $p_X(a) = P(X = a)$  se nazývá pravděpodobnostní funkce diskrétní veličiny  $X$ , případně pravděpodobnostní rozdělení veličiny  $X$ . Lze definovat pouze na oboru hodnot  $X$ .

Povšimněme si.

$$\sum_{a \in \mathbb{R}} p_X(a) = \sum_{a \in H_X} p_X(a) = 1,$$

kde  $H_X$  označuje obor hodnot  $X$ .

**Příklad.** Indikátor jevu. Hození kostkou.

$$X = \begin{cases} 0 & \text{nepadlo 6} \\ 1 & \text{padlo 6} \end{cases}.$$

$$X(\omega) = \begin{cases} 0 & \omega \notin A \\ 1 & \omega \in A \end{cases}.$$

Určete  $p_X$ .  $X \in \{0, 1\}$

$$p_X(0) = P(X = 0) = \frac{5}{6} \tag{1}$$

$$p_X(1) = P(X = 1) = \frac{1}{6}. \tag{2}$$

**Příklad.** Házíme mincí než padne panna.

$X$  ... počet hodů, které jsme provedli

---

$$X \in \{1, 2, 3, 4, \dots\}.$$

$$p_X(i) = P(X = i) = 2^{-i}, i \in \mathbb{N}.$$



**Povšimněme si.**  $\forall I \subseteq \mathbb{R}$ ,  $I$  interval

$$\sum_{a \in I} p_X(a) = \sum_{a \in I} P(X = a) = P(X \in I).$$

**Definice 7.3.** Spojitá náhodná veličina

Náhodná veličina  $X$  se nazývá spojitě rozdělená (spojitá), pokud existuje integrovatelná nezáporná funkce  $f : \mathbb{R} \rightarrow \mathbb{R}$ , pro kterou platí, že pro každý interval  $I \subseteq \mathbb{R}$ ,  $P(X \in I) = \int_I f dx$ .

Tj. pokud  $I = [a, b]$ ,  $P(a \leq X \leq b) = \int_a^b f(x) dx$ .

Funkce  $f$  se nazývá hustota náhodné veličiny  $X$ .

**Definice 7.4.** Distribuční funkce

Nechť  $X$  je náhodná veličina.

Funkce  $F_X : \mathbb{R} \rightarrow [0, 1]$  dána předpisem  $F_X(u) = P(X \leq u)$ ,  $u \in \mathbb{R}$  se nazývá distribuční funkce náhodné veličiny  $X$ .

$F_X$  vždy existuje.

**Povšimněme si.**

$$F_X(u) = \int_{-\infty}^u f_X(t) dt, F'_X(u) = f_X(u).$$

pro  $X$  spojitě.

## Přednáška 8: Náhodné veličiny

11. 3. 2021

**Věta 8.1.** Vlastnosti  $F_X$

Nechť  $F_X : \mathbb{R} \rightarrow [0, 1]$  je dist. fce. n. v.  $X$ .

Potom platí:

1.  $F_X$  je neklesající
2.  $\lim_{u \rightarrow \infty} F_X(u) = 1$ ,  $\lim_{u \rightarrow -\infty} F_X(u) = 0$
3.  $F_X$  je zprava spojitá

**Věta 8.2** (Distribuční funkce a náhodná veličina). Kdykoliv  $F : \mathbb{R} \rightarrow [0, 1]$  je funkce splňující 1. - 3., existuje náhodná veličina  $X$  taková, že  $F$  je distribuční funkce  $X$ .

**Příklad.** Pro získání náhodné veličiny z distribuční funkce stačí vzít  $\Omega = \mathbb{R}$ .

$\mathcal{A}$  = měřitelné podmnožiny

$P$  bude definovaná skrze hodnoty na intervalech typu  $(a, b]$ , kde  $P((a, b]) = F(b) - F(a)$ .

$X : \mathbb{R} \rightarrow \mathbb{R}, X(t) = t$

**Důsledek 8.2.1.** Není třeba dále pracovat s pravděpodobnostními prostory  $\Omega$ . Stačí pracovat s rozdělením pravděpodobnosti hodnot  $X$  na  $\mathbb{R}$ . To je jednoznačně určeno pomocí  $F_X$ .

Když tímto způsobem definujeme pravděpodobnost na  $\mathbb{R}$ , dostáváme pstní prostor.

$$\forall I \subseteq \mathbb{R} : P(I) := P(X^{-1}(I)).$$

**Věta 8.3.** Nechť  $X$  je diskrétně rozdělená náhodná veličina a  $Y$  je spojitě rozdělená náhodná veličina. Potom platí pro libovolné  $t \in \mathbb{R}$ :  $F_X(t) = \sum_{a \leq t} p_X(a)$ ,  $F_Y(t) = \int_{-\infty}^t f(a) da$

**Příklad.** Náhodná veličina  $X$  je dána jako počet panen při hodu dvěma mincemi. Nalezněte  $F_X$ .

$$F_X(u) = P(X \leq u) = \begin{cases} 0 & u < 0 \\ \frac{1}{4} & u \in [0, 1) \\ \frac{3}{4} & u \in [1, 2) \\ 1 & u \geq 2 \end{cases}.$$

**Příklad.**  $X$  je dána jako vzdálenost náhodně vybraného bodu z kruhu o poloměru  $a > 0$  od kraje kruhu. Určete  $F_X$  a  $f_X$ .

$$F_X(u) = P(X \leq u) = \begin{cases} 0 & u < 0 \\ 1 - \frac{\pi(a-u)^2}{\pi a^2} = 1 - \left(\frac{a-u}{a}\right)^2 & u \in [0, a) \\ 1 & u \geq a \end{cases}.$$

$$f_X = F'_X(u) = \begin{cases} \frac{-2u}{a^2} + \frac{2}{a} & u \in [0, a) \\ 0 & \text{jinak} \end{cases}.$$

**Definice 8.4** (Střední hodnota). Nechť  $X$  je n. v. Pokud je  $X$  diskrétní, potom definujeme její střední hodnotu jako

$$EX = \sum_{a \in \mathbb{R}} a \cdot p_X(a).$$

Pokud je  $X$  spojitá, potom definujeme její střední hodnotu jako

$$EX = \int_{-\infty}^{\infty} x \cdot f(x) dx,$$

kde  $f$  je hustota

## Přednáška 9: Náhodné veličiny

17. 3. 2021

**Věta 9.1.** Nechť  $X$  je náhodná veličina taková, že její distribuční funkce  $F_X$  je spojitá a má konečnou derivaci všude až na spočetně mnoho bodů. Potom je náhodná veličina  $X$  spojitě rozdělená.

*Důkaz.* nástin důkazu: definuji  $M = \{u | u \in \mathbb{R}, F_X \text{ nemá konečnou derivaci v } u\}$ . Zřejmě  $M$  je nejvýše spočetná, a proto  $\forall I = (a, b] \subseteq \mathbb{R}$ , platí  $\int_{I \setminus M} 1 = \lambda(I) = b - a$ .

chci  $\exists f : \mathbb{R} \rightarrow \mathbb{R}, f \geq 0$ , integrovatelná, že  $\forall I \ P(X \in I) = \int_I f(x) dx$ . Vezmu

$$f(u) = \begin{cases} F'_X(u) & u \notin M \\ 0 & u \in M \end{cases}.$$

Vezmu  $I = (a, b]$ . Potom dle definice

$$\begin{aligned} P(X \in I) &= F_X(b) - F_X(a) = F_X(b^-) - F_X(a^+) \\ &= [F_X(u)]_{u=a}^{u=b} = \int_{I \setminus M} F'_X(u) du = \int_I f(u) du \end{aligned}$$

Integrovatelnost  $f$  plyne z

$$\int_{\mathbb{R}} |f(x)| dx = \int_{\mathbb{R}} f(x) dx = \int_{-\infty}^{\infty} f(x) dx = F_X(\infty^-) - F_X(-\infty^+) = 1 - 0 = 1 < \infty.$$

Kde první úprava je možná, neboť  $f(x) = F'(x)$  a  $F$  je neklesající.  $\square$

**Příklad** (Devil's staircase). Odstrašující příklad. Fce, která je spojitá, ale nemá v nespočetně mnoha bodech derivaci a navíc má množina těchto bodů Lebesgueovu míru 0. (tedy ta fce má skoro všude derivaci)

Derivace je nulová skoro všude, tedy integrál bude nulový. Viz Wikipedia (EN).

K definici střední hodnoty. Nechť  $X$  je náhodná veličina,  $X : \Omega \rightarrow \mathbb{R}$ . Obecně se definuje střední hodnota  $X$  jako

$$EX = \int_{\Omega} X(\omega) dP(\omega) = \int_{\mathbb{R}} u dF(u).$$

Kde  $dF$  je pst. na  $\mathbb{R}$ , kterou získáme přenesením  $P$  z  $\Omega$  na  $\mathbb{R}$  pomocí  $X$ .

$$B \subseteq \mathbb{R} : dF(B) = P(X \in B) = P(\{\omega | \omega \in \Omega, X(\omega) \in B\}) = P(X^{-1}(B))$$

## Vlastnosti střední hodnoty

Nechť  $X$  je n. v.  $Y$  je n. v.  $X : \Omega \rightarrow \mathbb{R}$

1.  $\forall c \in \mathbb{R} : Ec = c$
2.  $\forall c \in \mathbb{R} : E(cX) = cEX$
3.  $E(X+Y) = EX + EY$
4.  $\forall g : \mathbb{R} \rightarrow \mathbb{R}$ ,  $g$  měřitelná

$$Eg(X) = \int_{\Omega} g(X) dP = \int_{\mathbb{R}} g(u) dF(u).$$

Speciální případ  $X$  je spojitá

$$Eg(X) = \int_{-\infty}^{\infty} g(u) f(u) du.$$

Speciální případ  $X$  je diskrétní

$$Eg(X) = \sum_{a \in \mathbb{R}} g(a) p_X(a).$$

5.  $X, Y$  pro které  $X \leq Y$  skoro všude, potom  $EX \leq EY$ .
6. Jensenova nerovnost. Je-li  $g : \mathbb{R} \rightarrow \mathbb{R}$  konvexní, potom  $g(EX) \leq Eg(X)$

*Důkaz.* 1.  $c \in \mathbb{R}$  chápeme jako konstantní veličinu.  $c$  je deterministická.  $X : \Omega \rightarrow \mathbb{R}, X(\omega) = c, X \in \{c\} \implies X$  je diskrétní

$$EX = c \cdot 1 = c.$$

2.

$$E(cX) = \int_{\mathbb{R}} c \cdot x \, dF(x) = c \cdot \int_{\mathbb{R}} x \, dF(x) = cEX.$$

Speciálně spojitá

$$E(cX) = \int_{\mathbb{R}} cx f_X(x) \, dx = c \int_{\mathbb{R}} x f_X(x) \, dx = cEX.$$

diskrétní

$$E(cX) = \sum_{a \in \mathbb{R}} ap_{cX}(a) = \sum_{a \in \mathbb{R}} ap(cX = a) = \sum_{a \in \mathbb{R}} cap(X = a).$$

3.

$$E(X + Y) = \int_{\Omega} (X + Y) \, dP = \int_{\Omega} X \, dP + \int_{\Omega} Y \, dP = EX + EY.$$

4.

$$Eg(X) = E(g \circ X) = \int_{\Omega} g \circ X(\omega) \, dP(\omega) = \int_{-\infty}^{\infty} a \, dF_{g \circ X}(a) = \int_{-\infty}^{\infty} g(u) \, dF_X(u).$$

Spojité případ

$$\int_{-\infty}^{\infty} g(u) f_X(u) \, du.$$

Diskrétní

$$\int_{-\infty}^{\infty} g(a) \cdot d \sum_i x_i \delta_{a_i} = \sum_i g(a_i) \cdot x_i = \sum_i g(a_i) \cdot P(X = a_i) = \sum_{a \in \mathbb{R}} g(a) \cdot p_X(a).$$

5.

$$EX = \int_{\Omega} X \, dP \leq \int_{\Omega} Y \, dP = EY,$$

neboť  $P(B) \geq 0, B \subseteq \mathcal{A}$

6. Zřejmé.

□

**Definice 9.2** (n-tý (centrální) moment). Nechť  $X$  je náhodná veličina a  $n \in \mathbb{N}$

- Hodnotu  $EX^n$  nazýváme n-tý moment n. v.  $X$ .
- $E|X|^n$  nazýváme n-tý absolutní moment n. v.  $X$ .
- $E|X - EX|^n$  nazýváme n-tý (absolutní) centrální moment n. v.  $X$ .

Speciálně:

- $E|X - EX|$  nazýváme absolutní odchylku od průměru
- $\text{var } X = DX = E|X - EX|^2$  nazýváme rozptyl n. v.  $X$
- $\sqrt{DX} = (E|X - EX|^2)^{\frac{1}{2}}$  nazýváme směrodatná odchylka. Často značíme  $\sigma_x$

## Přednáška 10: Rozdělení náhodných veličin

18. 3. 2021

**Příklad.** Spočítejte  $E|X - EX|$  pro  $X \sim U[0, 1]$  (rovnoměrné rozdělení)

$$F_X(u) = P(X \leq u) = \begin{cases} 0 & u < 0 \\ u & u \in [0, 1] \\ 1 & u \geq 1 \end{cases}.$$

platí:

$$F'_X(u) = f(u),$$

až na spočetně mnoho bodů.

$$f(u) = \begin{cases} 0 & u \notin (0, 1) \\ 1 & u \in (0, 1) \end{cases}.$$

$$EX = \int_{-\infty}^{\infty} u \cdot f(u) du = \int_{-\infty}^0 u \cdot 0 du + \int_0^1 u \cdot 1 du + \int_1^{\infty} u \cdot 0 du = \left[ \frac{u^2}{2} \right]_0^1 = \frac{1}{2}.$$

$$E|X - EX| = E\left|X - \frac{1}{2}\right| = \int_{-\infty}^{\infty} \left|u - \frac{1}{2}\right| \cdot f(u) du = \int_0^1 \left|u - \frac{1}{2}\right| du = \frac{1}{4}.$$

**Věta 10.1.** Nechť  $X$  je n. v. s konečným 2. momentem. Potom:

1.  $E(X - EX) = 0$
2. (rozptyl)  $DX = E(X - EX)^2 = EX^2 - (EX)^2$
3.  $\forall a, b \in \mathbb{R} \quad D(aX + b) = a^2 DX$

$$4. MAD(aX + b) = |a| \cdot MAD(X)$$

*Důkaz.* Důkaz předchozí věty.

$$1. E(X - EX) = EX - E(EX) = EX - EX = 0$$

$$2. DX = E(X - EX)^2 = E(X^2 - 2X \cdot EX + (EX)^2) = EX^2 - E(2X \cdot EX) + E(EX)^2 = EX^2 - 2EX \cdot EX + (EX)^2 = EX^2 - 2(EX)^2 + (EX)^2 = EX^2 - (EX)^2$$

$$3. \text{nechť } a, b \in \mathbb{R}.$$

$$D(aX + b) = E(aX + b - E(aX + b))^2 = E(aX + b - aEX - b)^2 = E(aX - aEX)^2 = E(a(X - EX))^2 = a^2 E(X - EX)^2 = a^2 DX$$

$$4. MAD(aX + B) = E|aX + b - E(aX + b)| = E|a(X - EX)| = |a|MAD(X)$$

□

## Některé typy pstních rozdělání

Když se veličina  $X$  řídí rozdělením  $B$  s parametry  $(\alpha, \beta, \gamma, \dots)$ , značíme to  $X \sim B(\alpha, \beta, \gamma, \dots)$ .

### 10.1 Alternativní rozdělení (nula-jedničkové, indikátor jevu)

parametr  $p$ :

$$X \sim Alt(p).$$

$$P(X = 0) = 1 - p.$$

$$P(X = 1) = p.$$

#### Charakteristiky

- $X \sim Alt(p)$
- $EX = 0(1 - p) + 1p = p$
- $EX^n = 0^n(1 - p) + 1^n p = p$
- $DX = EX^2 - (EX)^2 = p - p^2 = p(1 - p)$

**Příklad.** Počet panen v jednom hodu mincí, kde panna má pst  $p$ .

## 10.2 Binomické rozdělení

parametry  $n \in \mathbb{N}, p \in [0, 1]$

značíme  $X \sim \text{Bi}(n, p)$ , pokud  $X \in \{0, 1, 2, \dots, n\}$ ,  $\forall k \in \{0, 1, \dots, n\} : P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$

### Charakteristiky

- $EX = np$
- $DX = np(1-p)$

**Příklad.** Počet panen v hodu  $n$ -mincemi, kde každá má pst panny  $p$ . (odpovídá součtu u nezávislých veličin s Alt rozdělením s parametrem  $p$ )

## 10.3 Geometrické rozdělení

parametr  $p \in (0, 1]$

značíme  $X \sim \text{Geom}(p)$

$$P(X = k) = p(1-p)^{k-1}$$

### Charakteristiky

- $EX = \sum_{k=1}^{\infty} k \cdot p \cdot (1-p)^{k-1} = p \cdot \sum_{k=0}^{\infty} k(1-p)^{k-1} = p \cdot \frac{1}{p^2} = \frac{1}{p}$   
 $\varphi'(k) = \sum_{k=0}^{\infty} k(1-p)^{k-1} = \frac{1}{p^2}$   
 $\varphi(k) = \sum_{k=0}^{\infty} -(1-p)^k = \frac{-1}{1-(1-p)} = -\frac{1}{p}$
- $DX = EX^2 - (EX)^2 = EX^2 - \frac{1}{p^2} = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2}$   
 $EX^2 = \sum_{k=1}^{\infty} k^2 p(1-p)^{k-1} = \sum_{k=1}^{\infty} k(k+1)p(1-p)^{k-1} - \sum_{k=1}^{\infty} kp(1-p)^{k-1} = \frac{2-p}{p^2}$

**Příklad.** Odpovídá počtu nezávislých pokusů do úspěchu, v každém pokusu je pst úspěchu  $p$ .

Házíme minci dokud nehodíme pannu.

## 10.4 Rovnoměrné rozdělení na intervalu

parametry  $a < b, a, b \in \mathbb{R}$

značíme  $X \sim U((a, b))$

$X$  nabývá hodnot z  $(a, b)$



hustota:

$$f(u) = \begin{cases} \frac{1}{b-a} & u \in (a, b) \\ 0 & u \notin (a, b) \end{cases}.$$

### Charakteristiky

- $EX = \int_{-\infty}^{\infty} u \cdot f(u) du = \int_a^b \frac{u}{b-a} = \left[ \frac{u^2}{2} \frac{1}{b-a} \right]_a^b = \frac{a+b}{2}$
- $DX = EX^2 - (EX)^2 = EX^2 - \left(\frac{a+b}{2}\right)^2 = \frac{b^2-2ab+a^2}{12} = \frac{(b-a)^2}{12}$
- $EX^2 = \int_{-\infty}^{\infty} u^2 \cdot f(u) du = \frac{b^3-a^3}{3(b-a)} = \frac{b^2-ab+a^2}{3}$

## Přednáška 11: Rozdělení náhodných veličin

24. 3. 2021

### 11.1 Poissonovo rozdělení (rozdělení řídkých jevů)

parametr  $\lambda, \lambda > 0$

$$X \in \{0, 1, 2, 3, 4, \dots\}$$

$$p_X(n) = P(X = n) = e^{-\lambda} \cdot \frac{\lambda^n}{n!}, n \in \mathbb{N}_0$$

### Charakteristiky

- $EX = \sum_{n=0}^{\infty} n \cdot e^{-\lambda} \cdot \frac{\lambda^n}{n!} = e^{-\lambda} \lambda \sum_{n=1}^{\infty} \frac{\lambda^{n-1}}{(n-1)!} = \lambda e^{-\lambda} e^{\lambda} = \lambda$
- $DX = EX^2 + (EX)^2 = \lambda^2 + \lambda - \lambda^2 = \lambda EX^2 = e^{-\lambda} \sum_{n=0}^{\infty} n^2 \frac{\lambda^n}{n!} = \dots = \lambda^2 + \lambda$

**Příklad.** Počet dopisů, které dostaneme za rok.

Poissonovo rozdělení lze získat jako limitní případ binomického rozdělení, kde  $n \rightarrow \infty$ ,  $p \rightarrow 0$ ,  $np \rightarrow \lambda$

$n$  lidí, z nichž každý mi pošle dopis, s pstí  $p$ , posílají nezávisle.

**Příklad** (špatný příklad (školácký)). Počet příchozích hovorů telefonní ústředny za den. (nesplňuje předpoklad nezávislosti: př. ústředna O2, jev ... vypadne internet v Praze)

### 11.2 Exponenciální rozdělení

modelujeme pomocí něj dobu mezi dvěma událostmi, jejichž počet se řídí Poissonovým rozdělením.

parametr  $\lambda, \lambda > 0$

$$x \in \mathbb{R}$$

hustota  $X \sim \text{Exp}(\lambda)$

$$f_X(u) = \begin{cases} \lambda e^{-\lambda u} & u > 0 \\ 0 & u \leq 0 \end{cases}$$

### Charakteristiky

- $EX = \int_{-\infty}^{\infty} x f_X(x) dx = \int_0^{\infty} x \lambda e^{-\lambda x} dx = \left[ x \frac{e^{-\lambda x}}{-\lambda} \lambda \right]_0^{\infty} - \int_0^{\infty} \lambda \frac{e^{-\lambda x}}{-\lambda} dx = 0 + \int_0^{\infty} e^{-\lambda x} dx = \left[ \frac{-e^{-\lambda x}}{\lambda} \right]_0^{\infty} = \frac{1}{\lambda}$
- $EX^2 = \int_{-\infty}^{\infty} x^2 f_X(x) dx = \int_0^{\infty} x^2 \lambda e^{-\lambda x} dx = \left[ x^2 \frac{e^{-\lambda x}}{-1} \right]_0^{\infty} + 2 \int_0^{\infty} x \frac{e^{-\lambda x}}{1} dx = 0 + \frac{2}{\lambda^2} = \frac{2}{\lambda^2}$   
 $DX = \frac{2}{\lambda^2} - \frac{1}{\lambda^2} = \frac{1}{\lambda^2}$

### Vlastnost (absence paměti)

$$\forall a, b > 0, X \sim \text{Exp}(\lambda) : P(X > a + b | X > a) = P(X > b).$$

**Příklad.** Podobné jako Poissonovo rozdělení, doba čekání do dalšího dopisu.

**Příklad.** Počet hodin, které žárovka vydrží svítit.

## 11.3 Gaussovo (normální) rozdělení

parametry  $\mu, \sigma^2, \mu \in \mathbb{R}, \sigma^2 > 0$  (případně  $\sigma = 0$ )

hustota  $X \sim N(\mu, \sigma^2)$ :

$$f_X(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

### Charakteristiky

- $EX = \dots = \mu \dots$  viz přednáška 06a
- $DX = EX^2 - (EX)^2 = \sigma^2$

**Příklad.** Výška jedince z jedné skupiny/populace,

hmotnost ...

(Téměř libovolný fyzický atribut v rámci jednoho druhu.)

Pevný bod Fourier transformace.

$$\psi(x) = e^{\frac{-x^2}{2}} \frac{1}{\sqrt{2\pi}}.$$

Její primitivní funkce není elementární.

$$\int_{-\infty}^{\infty} e^{\frac{-x^2}{2}} dx = \sqrt{2\pi}.$$

$X \sim N(\mu, \sigma^2)$  ...  $X$  má normální rozdělení se střední hodnotou  $\mu$  a rozptylem  $\sigma^2$ .

$X \sim N(0, 1)$ , normované normální rozdělení

**Příklad.**  $X \sim N(\mu, \sigma^2)$

$$P(\mu - \sigma \leq X \leq \mu + \sigma) = 68\%.$$

$$P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) = 95\%.$$

$$P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) = 99.7\%.$$

**Věta 11.1.** Necht'  $X \sim N(\mu, \sigma^2)$ ,  $\sigma^2, \mu \in \mathbb{R}$

Potom pro každé dvě čísla  $a, b \in \mathbb{R}$  platí  $aX + b \sim N(a\mu + b, a^2\sigma^2)$

*Důkaz.* Necht'  $X \sim N(\mu, \sigma^2)$

Potom  $P(X \leq u) = \int_{-\infty}^u \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(\mu-x)^2}{2\sigma^2}} dx$

Pro a kladné

$$\begin{aligned} P(aX + b \leq u) &= P(X \leq \frac{u-b}{a}) = \int_{-\infty}^{\frac{u-b}{a}} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(\mu-x)^2}{2\sigma^2}} dx \\ &= \int_{-\infty}^u \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{\left(\mu - \frac{y-b}{a}\right)^2}{2\sigma^2}\right) \frac{dy}{a} \\ &= \int_{-\infty}^u \frac{1}{\sqrt{2\pi a^2 \sigma^2} \exp\left(\frac{(\mu a + b - y)^2}{2a^2 \sigma^2}\right)} dy \end{aligned}$$

$$\sigma_1^2 = a^2 \sigma^2, \mu_1 = a\mu + b$$

Pro a záporné

$$\int_{-\infty}^u \frac{1}{\sqrt{2\pi\sigma^2} \exp(-\frac{(a\mu+b-y)^2}{2a^2\sigma^2})} dy$$

$$= 1 - \int_{-\infty}^u \frac{1}{\sqrt{2\pi\sigma^2}} \exp(-\frac{(a\nu+b-y)^2}{2a^2\sigma^2}) dy$$

Pro  $a = 0$

$$X \sim N(\mu, \sigma^2), aX + b \sim N(b, 0),$$

$aX + b$  je deterministické, konstanta  $b$ .

Zkonverguje na Diraca v bodě  $b$ . Veličina je konstantní.  $a = 0, aX + b = b$

□

**Důsledek 11.1.1.** Necht'  $X \sim N(\mu, \sigma^2), \sigma^2 > 0$ .

Potom normalizovaná veličina  $U = \frac{x-\mu}{\sigma}$  má rozdělení  $U \sim N(0, 1)$

$$E\left(\frac{X-\nu}{\sigma}\right) = \frac{EX-\nu}{\sigma} = \frac{\mu-\mu}{\sigma} = 0$$

$$D\left(\frac{X-\nu}{\sigma}\right) = \dots = 1$$

## Přednáška 12: Rozdělení náhodných veličin

25. 3. 2021

### 12.1 Paretovo rozdělení (někdy také 80:20 rozdělení)

parametr (pro nás stačí jeden)  $\alpha, \alpha > 0$

distribuční funkce

$$F_X = \begin{cases} 1 - \frac{1}{u^\alpha} & u \geq 1 \\ 0 & u < 1 \end{cases}$$

hustota

$$f_X(u) = \begin{cases} \frac{\alpha}{u^{\alpha+1}} & u \geq 1 \\ 0 & u < 1 \end{cases}$$

### Charakteristiky

- Střední hodnota

$$EX = \int_{-\infty}^{\infty} x f_X(x) dx = \int_1^{\infty} \alpha x^{-\alpha} dx = \begin{cases} \int_1^{\infty} \frac{1}{x} dx = [\log x]_1^{\infty} = \infty & \alpha = 1 \\ \int_1^{\infty} \left[ \frac{x^{1-\alpha}}{-\alpha+1} \right]_1^{\infty} = \infty & \alpha < 1 \\ \left[ \frac{x^{1-\alpha}}{-\alpha+1} \right]_1^{\infty} = \frac{\alpha}{\alpha-1} & \alpha > 1 \end{cases}$$

$$\Rightarrow \alpha \leq 1 \dots EX = \infty$$

$$\Rightarrow \alpha = 2 \dots EX = 2$$

$$\Rightarrow \alpha = \frac{6}{5} \dots EX = \frac{6}{5} \frac{5}{1} = 6$$

$$\Rightarrow \alpha = \frac{11}{10} \dots EX \frac{\frac{11}{10}}{\frac{1}{10}} = 11$$

- Pokud je střední hodnota nekonečná, rozptyl neexistuje. Rozptyl definujeme jen pro  $\alpha \geq 1$

$$DX = E(X - EX)^2 = EX^2 - (EX)^2 = \frac{\alpha}{\alpha - 2} - \left( \frac{\alpha}{\alpha - 1} \right)^2,$$

pokud  $\alpha > 2$

$$EX^2 = \int_{-\infty}^{\infty} u^2 f_X(u) du = \int_1^{\infty} u^2 \frac{\alpha}{u^{\alpha+1}} du = \begin{cases} \int_1^{\infty} \frac{\alpha}{u} du = [\alpha \log u]_1^{\infty} = \infty & \alpha = 2 \\ \left[ \frac{\alpha}{-\alpha+2} u^{-\alpha+2} \right]_1^{\infty} = \infty & \alpha \leq 2 \\ \left[ \frac{\alpha}{-\alpha+2} u^{-\alpha+2} \right]_1^{\infty} = \frac{\alpha}{\alpha-2} & \alpha > 2 \end{cases}$$

**Příklad.** motivace: Italský účetní Pareto: "20 % farmářů vlastní 80 % země (pozemků)"

### Přednáška 13: Náhodné vektory

31. 3. 2021

**Definice 13.1.** Necht'  $(\Omega, \mathcal{A}, P)$  je pstní prostor,  $n \in \mathbb{N}$ .

Zobrazení  $X : \Omega \rightarrow \mathbb{R}^n$  nazvu (n-rozměrný) náhodný vektor, pokud pro každý kvádr  $K = I_1 \times I_2 \times \dots \times I_n \subseteq \mathbb{R}_n$ ,  $I_i$  jsou libovolné reálné intervaly, platí  $X^{-1}(K) \in \mathcal{A}$ .

**Příklad.** náhodně vyberu jedince z populace

$$X = (\text{výška}, \text{váha}, \text{indikátor pohlaví})$$

**Příklad.**

$$X = (X_1, \dots, X_n)$$

$X_i$  cena námi stanovené i-té akcie při otevření trhu.

**Definice 13.2.** Necht'  $X$  n-rozměrný n. vekt. Funkce  $F : \mathbb{R}^n \rightarrow [0, 1]$  definovaná vztahem

$$F(x) = P(X_1 \leq x_1, X_2 \leq x_2, \dots, X_n \leq x_n), x \in \mathbb{R}^n, X = (X_1, \dots, X_n)$$

se nazývá (sdružená) distribuční funkce n. vektoru  $X$ .

**Tvrzení 13.3.** Pokud  $(\Omega, \mathcal{A}, P)$  je pstní prostor,  $u \in \mathbb{R}$  a  $X : \Omega \rightarrow \mathbb{R}^n$  je n. vektor, potom na  $\mathbb{R}^n$  lze definovat pst  $P^*$  vzorcem

$$P^*(B) = P(X^{-1}(B)), B \subseteq \mathbb{R}^n,$$

B měřitelná.

Tuto pst  $P^*$  budeme někdy značit  $dF$ , kde  $F$  je dist. fce vektoru  $X$ .

**Vlastnosti 13.4.** Vlastnosti  $F_X$ .

Nechť  $X$  je n-rozměrný náhodný vektor s dist. fcí  $F$ . Potom platí:

1.  $F$  je v každé proměnné neklesající.
2. Pokud  $x \in \mathbb{R}^n, y_i \in \mathbb{R}^n, x < y_i, i \in \{1, \dots, n\}$

$$\lim_{k \rightarrow \infty} F(y^k) = F(x)$$

3.  $\forall k \in \{1, \dots, n\}, x \in \mathbb{R}^n$ :

$$\lim_{u \rightarrow -\infty} F((x_1, x_2, \dots, x_{k-1}, u, x_{k+1}, \dots, x_n)) = 0$$

$$\lim_{x_1 \rightarrow \infty} \lim_{x_2 \rightarrow \infty} \dots \lim_{x_n \rightarrow \infty} F_x(x) = 1$$

**Definice 13.5.** Buď  $X$  n-rozměrný n. vektor.  $X$  nazvu diskrétně rozdělený, existuje-li nejvýše spočetná množina  $A = \{a_1, a_2, \dots\} \subseteq \mathbb{R}^n$  a nezáporná čísla  $p_1, p_2, p_3, \dots$  pro něž platí

$$\sum_{i=1}^{\infty} p_i = 1, \forall i \in \mathbb{N} : P(X = a_i) = p_i.$$

Pozn. Je-li  $X$  diskrétně rozdělený vektor, potom  $X_1, \dots, X_n$  jsou diskrétně rozdělené a naopak

**Definice 13.6.**  $X$  nazýváme spojitě rozdělený, pokud existuje nezáporná integrovatelná (a tedy měřitelná) fce  $f : \mathbb{R}^n \rightarrow \mathbb{R}$  splňující

$$P(X \in K) = \int_K f dx,$$

pro každý n-rozměrný kvádr  $K$ .

**Definice 13.7.** Buď  $X = (X_1, \dots, X_n)$  náhodný vektor. Rozdělení veličin  $X_i$  často označujeme jako marginální rozdělení. Distribuční funkce n. vektoru  $X$  se často nazývá sdružená dist. f. (analogicky  $f$  je sdružená hustota)

**Věta 13.8.** Pro n vektor  $X = (X_1, \dots, X_n)$  a jeho dist. fci  $F$  lze marginální distribuční funkce veličiny  $X_k$  určit jako

$$\begin{aligned} & \lim_{x_1 \rightarrow \infty} \lim_{x_2 \rightarrow \infty} \dots \lim_{x_n \rightarrow \infty} F((x_1, x_2, x_{k-1}, \dots, u, x_{k+1}, \dots, x_n)) \\ &= P(X \in (-\infty, \infty) \times (-\infty, \infty) \times \dots \times (-\infty, u] \times (-\infty, \infty) \dots (-\infty, \infty)) \cdot \\ &= P(X_k \in (-\infty, u]) = F_{X_k}(u) \end{aligned}$$

**Tvrzení 13.9.** Nechť  $X$  je spojitý, n-rozměrný n. vektor se sdruženou hustotou  $f$  a sdruženou distribuční funkcí  $F$ .

Potom  $F$  je spojitá funkce mající skoro všude derivaci a platí 1)

$$\frac{\partial^n F}{\partial x_1 \partial x_2 \dots \partial x_n}(u) = f(u),$$

(pro  $\lambda_n$ -skoro všechna  $u$ )

Platí 2)

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \int_{-\infty}^{x_2} \dots \int_{-\infty}^{x_n} f(u_1, \dots, u_n) du_n \dots du_1$$

*Důkaz.* Tvrzení

1. spojitost integrálu vůči mezím a 1)  $\implies F$  je spojitá.
2. Vezmeme kvádr  $k = (-\infty, x_1] \times \dots \times (-\infty, x_n]$

$$F(x_1, \dots, x_n) = P(X \in k) = \int_K f du \dots$$

□

## Přednáška 14: Příklady na náhodné vektory, jejich charakteristiky

1. 4. 2021

Příklady na náhodné vektory viz přednáška na Youtube.

**Příklad.** N. vektor  $(X, Y)$  má rozdělení hodnot dané tabulkou

$X \setminus Y$	0	1
0	0.2	0.3
1	0.2	0.3

$$(X, Y) \in \{(0, 0), (0, 1), (1, 0), (1, 1)\}$$

Pro představu  $p_{X,Y}(0, 0) = 0.2, p_{X,Y}(0, 1) = 0.3$ .

Určete marginální rozdělení veličin X a Y.

$$X \in \{0, 1\}$$

$$P(X = 0) = P(X = 0 \wedge Y = 0) + P(X = 0 \wedge Y = 1) = 0.2 + 0.3 = 0.5$$

$$P(X = 1) = 1 - P(X = 0) = 0.5$$

$$P(Y = 0) = P(Y = 0 \wedge X = 0) + P(Y = 0 \wedge X = 1) = 0.2 + 0.2 = 0.4$$

$$P(Y = 1) = 1 - P(Y = 0) = 0.6$$

Veličiny mají alternativní rozdělení.

#### 14.1 Charakteristiky náhodných vektorů

**Definice 14.1.** Buď  $X = (X_1, \dots, X_n), n \in \mathbb{N}$  náhodný vektor.

$$EX = (EX_1, \dots, EX_n)$$

nazýváme střední hodnotu.

Pozn. geometricky odpovídá poloze těžiště.

**Definice 14.2.**

$$\text{var } X = \{cov(X_i, X_j)\}_{i,j=1}^n,$$

kde  $cov(Y, Z) = E(Y - EY)(Z - EZ)$  je kovariance veličin Y a Z.

**Definice 14.3.**

$$\rho_X = \{\rho_{x_i, x_j}\}_{i,j=1}^n,$$

kde

$$\rho_{Y,Z} = \frac{cov(Y, Z)}{\sqrt{DY \cdot DZ}}$$

je korelační koeficient veličin Y a Z.



**Tvrzení 14.4.** Necht  $X, Y$  jsou n. v. s konečným druhým momentem.

Potom platí:

1.  $cov(X, Y) = cov(Y, X)$
2.  $cov(X, X) = DX$
3.  $cov(X, Y) = EXY - (EX)(EY)$
4.  $\rho_{X,Y} \in [-1, 1]$
5.  $a, b \in \mathbb{R} : cov(aX + b, Y) = E(aX + b)Y - (aEX + b)EY = aEXY + bEY - aEXEY - bEY = a \cdot cov(X, Y)$

*Důkaz.* 1.  $cov(X, Y) = E(X - EX)(Y - EY) = E(Y - EY)(X - EX) = cov(Y, X)$   
 $\implies$  variační matice je vždy symetrická

$$2. cov(X, X) = E(X - EX)(X - EX) = E(X - EX)^2 = DX$$

$$3. cov(X, Y) = E(X - EX)(Y - EY) = E(XY - YEX - XEY + EXEY) = E(XY) - EY \cdot EX - EX \cdot EY + EXEY = EXY - EXEY$$

4. Cauchy-Schwarz

$$\left| \frac{\langle u, v \rangle}{\|u\| \cdot \|v\|} \right| \leq 1$$

... zbytek na přednášce

□

**Definice 14.5.** Necht  $X_1, \dots, X_n$  jsou náhodné veličiny,  $n \in \mathbb{N}$ . Říkáme, že  $X_1, \dots, X_n$  jsou nezávislé, pokud pro každé  $(u_1, \dots, u_n) = u \in \mathbb{R}^n$  jsou jevy  $\{X_1 \leq u_1\}, \dots, \{X_n \leq u_n\}$  nezávislé.

**Tvrzení 14.6.** Necht  $X$  je n. vektor se sdruženou dist. fci  $F : \mathbb{R}^n \rightarrow [0, 1]$ . Veličiny  $X_1, \dots, X_n$  jsou nezávislé  $\iff \forall u \in \mathbb{R}^n$

$$F(u) = F_{X_1}(u_1) \cdot F_{X_2}(u_2) \dots \cdot F_{X_n}(u_n),$$

kde  $F_{X_i}$  je dist. fce. veličiny  $X_i$ .

Pro  $X$  spojitý vektor:  $X_1, \dots, X_n$  nezávislé  $\iff f_X = f_{x_1} \cdot f_{x_2} \cdot \dots \cdot f_{x_n}$

Pro  $X$  diskretní:  $X_1, \dots, X_n$  nezávislé  $\iff p_X = p_{X_1} \cdot \dots \cdot p_{X_n}$

## Přednáška 15: Náhodné vektory

7. 4. 2021

**Věta 15.1.** Necht'  $X_1, \dots, X_n$  jsou náhodné veličiny.

1. pokud  $X_1, \dots, X_n$  jsou diskrétní, potom jsou nezávislé právě tehdy, je-li vektor  $X$  diskrétní a platí

$$\forall a \in \mathbb{R}^n : p_{X_1, X_2, \dots, X_n}(a) = p_{X_1}(a_1) \cdot p_{X_2}(a_2) \cdot \dots \cdot p_{X_n}(a_n)$$

2. Jsou-li  $X_1, \dots, X_n$  spojité náhodné veličiny, potom  $X_1, \dots, X_n$  jsou nezávislé  $\iff$  vektor  $X$  je spojitě rozdělený a platí  $f_X = f_{x_1} \cdot f_{x_2} \cdot \dots \cdot f_{x_n}$  až na množiny dimenze  $< n$ .

Pozn. pokud  $\text{cov}(X, Y) = 0$ , potom říkáme, že jsou veličiny  $X, Y$  nekorelované. (korelace je nulová)

**Příklad.** Korelované veličiny

1. Výška a váha jedince (pokud je někdo vyšší, pravděpodobně bude vážit víc) neza-měňovat korelaci a kauzalitu vyšší  $\iff$  těžší. Ale pokud budu jíst a tloustnout, nevyrostu!
2. velikost reprodukčního indexu  $r$  v čase  $t$  a počet úmrtí v čase  $t + 20$

**Věta 15.2.** Necht'  $X, Y$  jsou nezávislé a  $EX^2, EY^2 < \infty$ , potom platí  $EXY = EXEY$

**Důsledek 15.2.1.** Necht'  $X, Y$  jsou n. v.,  $EX^2, EY^2 < \infty$ , nezávislé, potom  $\text{cov}(X, Y) = 0$  a  $\rho_{X,Y} = 0$

**Příklad.** Příklad na cov.

X/Y	-1	0	1
-1	0.1	0.3	0.1
1	0.25	0	0.25
	0.35	0.3	0.35

$X, Y$  nejsou nezávislé.

$$P(X = 1, Y = 0) = 0 \neq 0.5 \cdot 0.3 = P(X = 1) \cdot P(Y = 0) \quad EY = 0 \quad EXY = 0$$

$$\text{cov}(X, Y) = EXY - EXEY = 0 - 0 = 0$$

**Příklad.**  $X \sim U[-1, 1], Y = X^2$

$$EX = 0, \quad EX^3 = \int_{-1}^1 x^3 \frac{1}{2} dx = 0$$

$$\text{cov}(X, Y) = 0$$

Zjevně  $X$  a  $Y$  nejsou nezávislé ( $Y$  je definována pomocí  $X$ )

## Přednáška 16: Náhodné vektory

8. 4. 2021

**Tvrzení 16.1.** Necht'  $X, Y$  jsou n. v. a  $EX^2, EY^2 < \infty$ .

Potom platí  $D(X + Y) = DX + DY + 2cov(X, Y)$ .

**Důsledek 16.1.1.** 1. Kdykoliv  $X, Y$  jsou nezávislé (nekorelované) veličiny s  $EX^2, EY^2 < \infty$ , máme  $D(X + Y) = DX + DY$

2. Induktivně pokud  $X_1, \dots, X_n$  jsou nezávislé n. v. s  $EX_i^2 < \infty$ , platí  $D(\sum_{i=1}^n X_i) = \sum_{i=1}^n DX_i$

**Příklad.** Necht'  $X \sim Bi(n, p)$ , ukažte, že  $DX = np(1 - p)$

$$X \sim Bi(n, p) \implies X = \sum_{i=1}^n X_i,$$

kde

$$X_i \sim Alt(p), X_1, \dots, X_n \text{ nezávislé.}$$

$$DX_i = p(1 - p) \implies DX = D\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n DX_i = n \cdot p(1 - p).$$

**Příklad.** Necht'  $X_1, \dots, X_n$  jsou n. v. se stejnou střední hodnotou a rozptylem. ( $\sigma^2 < \infty$ ). Necht'  $X_1, \dots, X_n$  jsou nezávislé.

Potom je

$$D\bar{X} = D\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} D\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n DX_i = \frac{1}{n^2} \cdot n \cdot \sigma^2 = \frac{\sigma^2}{n}$$

**Příklad.** Hrajeme hru.

1. hodíme mincí, naše výhra

panna ... 100 \$

orel ... 0 \$

2. hodíme 100x mincí, za každou pannu dostaneme dolar, za orla nic.

Poplatek za hru je 45 \$.

1. moje výhra  $X - 45$

$$X = \begin{cases} 100 & P(X = 100) = \frac{1}{2} \\ 0 & P(X = 0) = \frac{1}{2} \end{cases}$$

$$E(X - 45) = EX - 45 = 50 - 45 = 5$$

$$\begin{aligned} D(X - 45) &= D(X) = EX^2 - (EX)^2 \\ &= (100^2 \frac{1}{2} + 0^2 \frac{1}{2} - (50)^2 = \\ &5000 - 2500 = 2500, \sqrt{DX} = 50 \end{aligned}$$

2. moje výhra  $X - 45$

$$X_1, \dots, X_{100}, X_1 \sim \text{Alt}(\frac{1}{2})$$

$$E \sum_{i=1}^{100} X_i = 100 \cdot \frac{1}{2} = 50$$

$$Y = \sum_{i=1}^{100} X_i | E(Y - 45) = 50 - 45 = 5$$

$$DY = D \left( \sum_{i=1}^{100} X_i \right) = \sum_{i=1}^n DX_i = 100 \frac{1}{4} = 25, \sqrt{DY} = 5$$

**Tvrzení 16.2.** Necht  $X, Y$  jsou nezávislé, spojitě rozdělené veličiny.

Potom  $X + Y$  je spojitě rozdělená s hustotou

$$f_Z(u) = \int_{-\infty}^{\infty} f_X(t) \cdot f_Y(u - t) dt = f_X * f_Y(u)$$

*Důkaz.*

$$\begin{aligned} F_Z(u) &= P(X + Y \leq u) = \iint_{\{(x,y) \in \mathbb{R}^2 | x+y \leq u\}} f_{X,Y}(x,y) dx dy \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{u-x} f_{X,Y}(x,y) dy dx \\ &= \int_{-\infty}^{\infty} \int_{-\infty}^{u-x} f_X(x) f_Y(y) dy dx \\ &= \int_{-\infty}^{\infty} f_X(x) \left( \int_{-\infty}^{u-x} f_Y(y) dy \right) dx \\ &= \int_{-\infty}^{\infty} f_X(x) \cdot F_Y(u - x) dx \end{aligned}$$

$$F'_Z(u) = \frac{\partial}{\partial u} \int_{-\infty}^{\infty} f_X(x) \cdot F_Y(u - x) dx = \int_{-\infty}^{\infty} f_X(x) \cdot f_Y(u - x) dx$$

□

**Příklad.** Necht'  $X_1, \dots, X_n$  jsou nezávislé n. v.,  $X_i \sim N(\nu_i, \sigma_i^2)$ , potom

$$\sum_{i=1}^n X_i \sim N\left(\sum_{i=1}^n \nu_i, \sum_{i=1}^n \sigma_i^2\right)$$

.

Protože (důkaz pro  $X, Y \sim N(0, 1)$ )

$$f_X(u) = f_Y(u) = \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{u^2}{2}}$$

$$\begin{aligned} F_Z(u) &= \int_{-\infty}^{\infty} f_X(x) \cdot f_Y(u-x) dx \\ &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{x^2}{2}} \cdot \frac{1}{\sqrt{2\pi}} \cdot e^{-\frac{(u-x)^2}{2}} dx \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi} \exp\left(-\frac{1}{2}(x^2 + u^2 - 2xu + x^2)\right) dx \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{4}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{4} + xu - x^2} dx \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{4}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \cdot e^{-(x-\frac{u}{2})^2} dx \\ &= \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{4}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}2} e^{-\frac{y^2}{2}} dy \\ &= \frac{1}{\sqrt{4\pi}} e^{-\frac{u^2}{4}} \end{aligned}$$

## Přednáška 17: Limitní věty

14. 4. 2021

**Definice 17.1.** Necht'  $X_1, X_2, \dots$  je posloupnost náhodných veličin.

Říkáme, že veličiny  $X_1, X_2, X_3, \dots$  jsou nezávislé, pokud pro libovolnou  $n$ -tici  $X_{i_1}, \dots, X_{i_n}, i_1 < i_2 < \dots < i_n$  platí, že veličiny  $X_{i_1}, \dots, X_{i_n}$  jsou nezávislé.

**Věta 17.2.** Čebyševova nerovnost

1. Necht'  $X$  je náhodná veličina s  $E|X|^n < \infty$  pro jisté  $n \in \mathbb{N}$ . Potom pro každé  $\delta > 0$  platí

$$P(|X| > \delta) \leq \frac{E|X|^n}{\delta^n}$$

2. Pokud  $X$  je n. v. a  $EX^2 < \infty$ , potom pro každé  $\delta > 0$  platí:

$$P(|X - EX| \geq \delta) \leq \frac{DX}{\delta^2}$$

*Důkaz.* Předchozí věty

1. Necht'  $E|X|^n < \infty$

(důkaz pouze pro spojitou  $X$ )

$$\begin{aligned} E|X|^n &= \int_{-\infty}^{\infty} |x|^n \cdot f_X(x) dx \\ &\geq \int_{\{x \in \mathbb{R} \mid |x| \geq \delta\}} |x|^n \cdot f_X(x) dx \\ &\geq \int_{\{x \in \mathbb{R} \mid |x| \geq \delta\}} \delta^n \cdot f_X(x) dx \\ &= \delta^n \cdot \int_{\{x \in \mathbb{R} \mid |x| \geq \delta\}} f_X(x) dx \\ &= \delta^n P(|X| \geq \delta) \end{aligned}$$

A odtud

$$P(|X| \geq \delta) \leq \frac{E|X|^n}{\delta^n}$$

2. Necht'  $EX^2 < \infty$ ,  $Y = X - EX$ ,  $n = 2$ .  $EY^2 < \infty$  Potom pro každé  $\delta > 0$  platí

$$\begin{aligned} P(|X - EX| \geq \delta) &= P(|Y| \geq \delta) \\ &\leq \frac{EY^2}{\delta^2} = \frac{E(X - EX)^2}{\delta^2} = \frac{DX}{\delta^2} \end{aligned}$$

□

**Příklad.** Odhadněte pravděpodobnost se kterou bude součet 100 hodů kostkou v rozpětí 340 - 360.

$X_1, \dots, X_{100}$

$X_i$  ... hod  $i$ -tou kostkou

$$EX_i = 3.5, DX_i = EX_i^2 - (EX_i)^2 = \frac{91}{6} - (3.5)^2 = \frac{35}{12}$$

$$Y = \sum_{i=1}^{100} X_i$$

$$EY = 100 \cdot 3.5 = 350, DY = 100 \cdot \frac{35}{12} = \frac{25 \cdot 35}{3} = \frac{875}{3}$$

$$P(|Y - 350| < 10) = 1 - P(|Y - 350| \geq 10) \geq 1 - \frac{\frac{875}{3}}{100} \geq -1.92$$

$\implies$  Čebyšev nic neříká. :D

**Příklad.** Odhadněte pravděpodobnost se kterou bude součet 100 hodů kostkou v rozpětí 320 - 380.

$$X_1, \dots, X_{100}$$

$X_i$  ... hod i-tou kostkou

$$EX_i = 3.5, DX_i = EX_i^2 - (EX_i)^2 = \frac{91}{6} - (3.5)^2 = \frac{35}{12}$$

$$Y = \sum_{i=1}^{100} X_i$$

$$EY = 100 \cdot 3.5 = 350, DY = 100 \cdot \frac{35}{12} = \frac{25 \cdot 35}{3} = \frac{875}{3}$$

$$P(|Y - 350| < 30) = 1 - P(|Y - 350| \geq 30) \geq 1 - \frac{\frac{875}{3}}{900} \geq 0.67$$

...

**Věta 17.3.** (Slabý) zákon velkých čísel

Nechť  $X_1, X_2, X_3, \dots$  je posloupnost nezávislých n. veličin se stejnou střední hodnotou  $\mu < \infty$  a se stejným rozptylem  $\sigma^2 < \infty$ .

Potom pro každé  $\delta > 0$  platí

$$\lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| \geq \delta) = 0 \iff \lim_{n \rightarrow \infty} P(|\bar{X}_n - \mu| < \delta) = 1,$$

kde  $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$  je průměr n veličin.

*Důkaz.* (Slabého) zákona velkých čísel

Důkaz v zápiscích chybí. □

**Věta 17.4.** (Silný) zákon velkých čísel

Nechť  $X_1, X_2, \dots$  je posloupnost nezávislých n. veličin se stejnou střední hodnotou  $\mu < \infty$ . Potom platí

$$P(\lim_{n \rightarrow \infty} \bar{X}_n = \mu) = 1.$$

## Přednáška 18: Centrální limitní věta

15. 4. 2021

**Věta 18.1.** Centrální limitní věta

Nechť  $X_1, X_2, X_3, \dots$  je posloupnost nezávislých, stejně rozdělených (independent, identically distributed, i. i. d.) náhodných veličin s konečnou střední hodnotou  $\infty < \mu < \infty$  a rozptylem  $\sigma^2 < \infty$ .

Označme

$$U_n = \frac{\sum_{i=1}^n X_i - n \cdot \mu}{\sqrt{n \cdot \sigma^2}}.$$

Potom pro každé  $x \in \mathbb{R}$  platí

$$\lim_{n \rightarrow \infty} F_{U_n}(x) \rightarrow \Phi(x),$$

kde  $\Phi$  je dist. fce  $N(0, 1)$ .

Pozn.

$$U_n = \frac{\sum_{i=1}^n X_i - n \cdot \mu}{\sqrt{n \cdot \sigma^2}} = \frac{\frac{1}{n} \sum_{i=1}^n X_i - \mu}{\sqrt{\frac{\sigma^2}{n}}}.$$

**Povšimněme si.** dle zákona velkých čísel

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{n \rightarrow \infty} \mu \text{ skoro jistě}$$

$$D(U_n) = D\left(\frac{\sum X_i}{\sqrt{n\sigma^2}}\right) = \frac{1}{n\sigma^2} \cdot \sum_{i=1}^n DX_i = \frac{1}{n\sigma^2} n\sigma^2 = 1$$

**Příklad.** Mějme minci, kde panna padá s pravděpodobností  $3/4$ . Jaká je pst, že při 100 hodech panna padne alespoň 70x.

$$X_1, \dots, X_{100}$$

$$X_i \begin{cases} 0 & \text{orel v } i\text{-tém hodě} \\ 1 & \text{panna} \end{cases}$$

$$X_1, \dots, X_{100} \text{ nezávislé}$$

$$X_i \sim \text{Alt}(3/4)$$

$$EX_i = 3/4$$

$$DX_i = 3/4 \cdot \frac{1}{4} = \frac{3}{16} < \infty$$

$$\begin{aligned} P\left(\sum_{i=1}^{100} X_i \geq 70\right) &= P\left(\sum_{i=1}^{100} X_i - 75 \geq 70 - 75\right) \\ &= P\left(\frac{\sum_{i=1}^{100} X_i - 75}{\sqrt{100 \cdot \frac{3}{16}}} \geq \frac{70 - 75}{\sqrt{100 \cdot \frac{3}{16}}}\right) \\ &= P\left(U_{100} \geq -\frac{2}{\sqrt{3}}\right) = 1 - P\left(U_{100} < \frac{-2}{\sqrt{3}}\right) \end{aligned}$$



$U_{100}$  podle CLV má rozdělení blízké  $N(0, 1)$

$$1 - P\left(U_{100} < \frac{-2}{\sqrt{3}}\right) = 1 - \Phi\left(\frac{-2}{\sqrt{3}}\right) = 1 - \left(1 - \Phi\left(\frac{2}{\sqrt{3}}\right)\right) = \Phi\left(\frac{2}{\sqrt{3}}\right) = 0.875$$

**Příklad.** Kolik nejméně musím vytáhnout čísel z  $[0, 1]$ , aby pravděpodobnost, že jejich průměr byl menší než  $\frac{7}{12}$  byla alespoň 95 %.

$X_1, \dots, X_n \sim U[0, 1]$ , nezávislé.

$$EX_i = \frac{1}{2}$$

$$DX_i = \frac{1}{3} - \frac{1}{4} = \frac{1}{12}$$

$$P\left(\frac{1}{n} \sum_{i=1}^n X_i \leq \frac{7}{12}\right) \geq 0.95$$

$$P\left(\frac{\bar{X}_n - \frac{1}{2}}{\sqrt{\frac{1}{12n}}} \leq \frac{7/12 - \frac{1}{2}}{\sqrt{\frac{1}{12n}}}\right) \geq 0.95$$

$$P\left(U_n \leq \sqrt{\frac{n}{12}}\right) \geq 0.95$$

$$\Phi\left(\sqrt{\frac{n}{12}}\right) \geq 0.95$$

$$\sqrt{\frac{n}{12}} \geq \Phi^{-1}(0.95)$$

$$\sqrt{\frac{n}{12}} \geq 1.65$$

$$\sqrt{n} \geq 1.65 \cdot \sqrt{12}$$

$$n \geq 32.67$$

$$n \geq 33$$

Lze si dovolit aproximaci pro  $\sum_{i=1}^{33} X_i$  pro  $n = 33$ ? Ano. (Jde o případ rovnoměrného rozdělení na intervalu, které lze použít pro  $n \geq 12$  pod 1 %)

**Příklad.** Protipříklady na CLV.

$$X_1, X_2, X_3, \dots$$

$$X_i \sim Pa(1.4)$$

jak vypadá  $\sum_{i=1}^n X_i$

$$EX_i = \frac{1.4}{0.4} = 3.5$$

$$EX_i^2 = \infty \implies DX_i = \infty$$

Nemůžeme použít CLV.

## Přednáška 19: Důkaz CLV

21. 4. 2021

**Definice 19.1** (Charakteristická funkce (Inverzní Fourierova transformace)). n. v.  $X$  je definována jako  $\phi_X(t) = E(e^{itX})$ ,  $t \in \mathbb{R}$ .

Pro spojitě rozdělenou  $X$ :

$$\phi_X(t) = \int_{-\infty}^{\infty} e^{itx} \cdot f_X(x) dx$$

**Vlastnosti 19.2** (charakteristické funkce). 1.  $\phi_X(0) = E(e^{i \cdot 0 \cdot X}) = 1$

$$2. |\phi_X(t)| = |E(e^{itX})| \leq E|e^{itX}| \leq 1$$

$$3. \phi_{cX+d}(t) = E(e^{it(cX+d)}) = e^{idt} \cdot E(e^{ictX}) = e^{idt} \phi_X(ct)$$

4.

$$\begin{aligned} \left. \frac{d^n}{dt^n} \phi_X(t) \right|_{t=0} &= \left. \frac{d^n}{dt^n} \right|_{t=0} E e^{itX} \\ &= \int_{-\infty}^{\infty} \left. \frac{d^n}{dt^n} \right|_{t=0} e^{itx} dF(x) \\ &= \int_{-\infty}^{\infty} i^n x^n e^{ix \cdot 0} dF(x) \\ &= i^n \int_{-\infty}^{\infty} x^n dF(x) \\ &= i^n \cdot E(X^n) \end{aligned}$$

5. pokud  $X_1, \dots, X_n$  jsou nezávislé n. v., potom

$$\phi_{\sum_{k=1}^n X_k}(t) = E e^{it \sum_{k=1}^n X_k} = E \prod_{k=1}^n e^{itX_k} = \prod_{k=1}^n E e^{itX_k} = \prod_{k=1}^n \phi_{X_k}(t)$$

**Věta 19.3** (o spojitosti). Nechť  $F$  je dist. fce veličiny s char. fci  $\phi$ . Potom pro libovolnou posloupnost n. v.  $X_1, X_2, X_3, \dots$  s char. fcemi  $\phi_1, \phi_2, \dots$  a dist. fcemi  $F_1, F_2, \dots$  platí, že  $F_n \rightarrow F$  v každém bodě spojitosti  $F$  právě tehdy, když  $\phi_n \rightarrow \phi$  bodově.

**Tvrzení 19.4** (čemu je rovna charakteristická funkce normálního rozdělení).  $X \sim N(\mu, \sigma^2) \implies \phi_X(t) = e^{(it\mu - \frac{\sigma^2 t^2}{2})}$

Důkaz.

$$\begin{aligned}
\phi_X(t) &= Ee^{itX} = \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} e^{itx} \cdot e^{-\frac{x^2}{2}} dx \\
\phi'_X(t) &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} ix \cdot e^{itx} \cdot e^{-\frac{x^2}{2}} dx \\
&= -\frac{i}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} \cdot \frac{de^{-x^2/2}}{dx} dx \\
&= \frac{-i}{\sqrt{2\pi}} \left[ e^{itx} e^{-x^2/2} \right]_{-\infty}^{\infty} + \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} ite^{itx} \cdot e^{-x^2/2} dx \\
&= 0 - t \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \cdot e^{-x^2/2} \cdot e^{itx} dx \\
&= -t\phi_X(t)
\end{aligned}$$

Víme, že  $\phi'(t) = -t\phi(t)$ , z toho  $\frac{\phi'(t)}{\phi(t)} = -t$ , pak integrací:

$$\begin{aligned}
\log \phi(t) &= -\frac{t^2}{2} + c \\
\phi(t) &= e^{-t^2/2} \cdot k \\
\phi(0) &= 1 \implies k = 1
\end{aligned}$$

□

Důkaz. Důkaz CLV.

Postup důkazu: vezmeme veličiny  $X_1, X_2, X_3, \dots$  provedeme "F. transformaci" na veličinu  $U_n = \frac{\sum X_i - \mu n}{\sqrt{n\sigma^2}}$  sérií úprav zjistíme, že konverguje k char. fci rozdělení  $N(0, 1)$ . Z jednoznačnosti F. transformace  $\implies U_n \rightarrow N(0, 1)$  v distribuci.

$$U_n = \frac{\sum_{k=1}^n X_k - \mu \cdot n}{\sqrt{n\sigma^2}} = \frac{\bar{X}_n - \mu}{\sqrt{\frac{\sigma^2}{n}}} = \frac{1}{\sqrt{n}} \sum_{k=1}^n Z_k,$$

kde  $Z_k = \frac{X_k - \mu}{\sigma}$ ,  $EZ_k = 0$ ,  $DZ_k = 1$ .

$$\phi'_{Z_k}(0) = i \cdot EZ_k = 0, \phi(Z_k)''(0) = (-1)EZ_k^2 = -1$$

Taylor pro  $\phi_{Z_1}$  okolo 0:

$$\begin{aligned}
 \phi_{Z_1} \left( \frac{t}{\sqrt{n}} \right) &= \phi_{Z_1}(0) + \phi'_{Z_1}(0) \frac{t}{\sqrt{n}} + \phi''_{Z_1}(0) \cdot \left( \frac{t}{\sqrt{n}} \right)^2 \frac{1}{2} + o \left( \left( \frac{t}{\sqrt{n}} \right)^2 \right) \\
 &= 1 + 0 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \\
 &= 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right)
 \end{aligned}$$

$$\begin{aligned}
 \phi_{U_n}(t) &= \phi_{\frac{1}{\sqrt{n}} \sum_{k=1}^n Z_k}(t) \\
 &= \phi_{\sum_{k=1}^n Z_k} \left( \frac{t}{\sqrt{n}} \right) \\
 &= \prod_{k=1}^n \phi_{Z_k} \left( \frac{t}{\sqrt{n}} \right) \\
 &= \left( \phi_{Z_1} \left( \frac{t}{\sqrt{n}} \right) \right)^n \\
 &= \left( 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \right)^n \\
 &= e^{n \cdot \log \left( 1 - \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \right)} \xrightarrow{n \rightarrow \infty} e^{-t^2/2} = \phi_X(t)
 \end{aligned}$$

Z toho:  $X \sim N(0, 1)$

□

## Přednáška 20: Konvergence CLV pro různá rozdělení, teorie odhadu

22. 4. 2021

Konvergence CLV pro různá rozdělení přednáška 10b.

**Definice 20.1** (Náhodný výběr). Nezávislé, stejně rozdělené veličiny  $X_1, \dots, X_n, n \in \mathbb{N}$  nazýváme náhodný výběr o rozsahu  $n$ . (Pokud mají např. dist. fci  $F$ , mluvíme o náhodném výběru z rozdělení  $F$ )

Libovolné hodnotě  $(x_1, x_2, \dots, x_n) \in \mathbb{R}^n$  vektoru  $(X_1, \dots, X_n)$  říkáme realizace  $n$  výběru.

To odpovídá tomu, že máme sérii  $n$  nezávislých experimentů/pozorování, které jsou za stejných podmínek.

**Příklad.** Hodíme  $n$ -krát mincí.  $X_i = \begin{cases} 0 & \text{v } i\text{-tém hodu padne orel} \\ 1 & \text{v } i\text{-tém hodu padne panna} \end{cases}$  Veličiny  $X_1, \dots, X_n$  tvoří náhodný výběr.

Realizací tohoto výběru může být např.  $(1, 0, 0, 0, \dots, 0)$

**Příklad.** Máme minci, která hází panna s pstí  $p$ . Chceme odhadnout  $p$ , (nám bude stačit stanovit, jestli  $p = \frac{1}{2}$ ).

Postup: hodíme 1000x mincí. Realita: panna padla 523x.

Otázka: jak je pravděpodobné, že  $p = \frac{1}{2}$ ? Budeme postupovat podle CLV.

Za předpokladu, že  $p = \frac{1}{2}$ ,  $EX_i = \frac{1}{2}$ ,  $DX_i = \frac{1}{4}$ .

$$\begin{aligned} P\left(\sum_{i=1}^{1000} X_i \geq 523\right) &= P\left(\frac{\sum_{n=1}^{1000} X_i - 5000}{\sqrt{250}} \geq \frac{23}{\sqrt{250}}\right) \\ &= P\left(U_{100} \geq \frac{23}{\sqrt{250}}\right) = 1 - \Phi\left(\frac{23}{\sqrt{250}}\right) = 1 - 0.93 = 0.07. \end{aligned}$$

V praxi často chceme odhadovat hodnoty parametrů rozdělení nebo jejich charakteristiky, funkce.

**Definice 20.2** (bodový odhad parametru). Nechť  $X_1, \dots, X_n$  je  $n$ . výběr z rozdělení s parametrem (charakteristikou)  $\theta$ .

Libovolná funkce  $g(X_1, \dots, X_n)$  náhodného výběru  $X_1, \dots, X_n$ , která není závislá na  $\theta$  se nazývá bodový odhad parametru  $\theta$ .

**Příklad.** Máme výběr z rozdělení  $Alt(p)$ ,  $p > 0$ . Utvořte různé odhady parametru  $p$ . Jak jsou dobré?

1. Výběrový průměr

$$g(X_1, \dots, X_n) = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}_n \dots \text{značíme výběrový průměr.}$$

2. Ne úplně dobrý odhad

$$g(X_1, \dots, X_n) = \frac{\max X_i - \min X_i}{2}.$$

3. Velmi špatný příklad odhadu

$$g(X_1, \dots, X_n) = 0.$$

Je také bodový odhad.

**Definice 20.3** (nestranný odhad). Odhad parametru  $\theta$  se nazývá nestranný, pokud pro každou hodnotu  $\theta$  je

$$E_{\theta}g(X_1, \dots, X_n) = \theta$$

**Příklad.** Výběrový průměr  $\bar{X}_n$  je nestranný odhad střední hodnoty  $EX$ , pro  $EX < \infty$ .

*Důkaz.*

$$E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E\left(\sum_{i=1}^n X_i\right) = \frac{1}{n} \cdot n \cdot EX = EX$$

□

## Přednáška 21: Výběrový rozptyl, metoda maximální věrohodnosti

28. 4. 2021

Mějme  $X_1, \dots, X_n$  náhodný výběr.

Realizace  $(x_1, x_2, \dots, x_n)$ . Snažíme se určit parametr rozdělení.

Bodový odhad  $g : (X_1, \dots, X_n) \rightarrow \mathbb{R}$  pro  $k$ -rozměrný parametr. Bodový odhad je nezávislý na parametru.

Víme: Výběrový průměr  $\bar{X}$  je nestranný odhad střední hodnoty. (pokud střední hodnota existuje)

**Definice 21.1** (výběrový rozptyl). Nechť  $X_1, \dots, X_n$  je  $n$ . výběr. Veličinu

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

nazýváme výběrový rozptyl a  $S_n = \sqrt{S_n^2}$  výběrová směrodatná odchylka.

**Tvrzení 21.2.** Nechť  $X_1, \dots, X_n$  je  $n$ . výběr z rozdělení s rozptylem  $\sigma^2 < \infty$ . Potom platí  $ES_n^2 = \sigma^2$  ( $S_n^2$  nestranný odhad  $\sigma^2$ )

*Důkaz.*

$$\begin{aligned}
 ES_n^2 &= \frac{1}{n-1} E \sum_{i=1}^n (X_i^2 - 2\bar{X} \cdot X_i + \bar{X}^2) \\
 &= \frac{1}{n-1} E \left( \sum_{i=1}^n X_i^2 - 2\bar{X}^2 n + n\bar{X}^2 \right) \\
 &= \frac{1}{n-1} E \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right)
 \end{aligned}$$

$$\begin{aligned}
 ES_n^2 &= \frac{1}{n-1} E \left( \sum_{i=1}^n X_i^2 - n\bar{X}^2 \right) \\
 &= \frac{1}{n-1} \left( \sum_{i=1}^n EX_i^2 - nE\bar{X}^2 \right) \\
 &= \frac{1}{n-1} (n \cdot EX_1^2 - (EX_1^2 + (n-1)(EX_1)^2)) \\
 &= \frac{1}{n-1} ((n-1)(EX_1^2 - (EX_1)^2)) = EX_1^2 - (EX_1)^2 = DX = \sigma^2
 \end{aligned}$$

$$\begin{aligned}
 E\bar{X}^2 &= E \left( \frac{1}{n} \sum_{i=1}^n X_i \right)^2 \\
 &= \frac{1}{n^2} E \left( \sum_{i=1}^n X_i \right)^2 \\
 &= \frac{1}{n^2} \left( \sum_{i=1}^n EX_i^2 + 2 \sum_{i<j} EX_i X_j \right) \\
 &= \frac{1}{n^2} \left( \sum_{i=1}^n EX_i^2 + 2 \sum_{i<j} EX_i \cdot EX_j \right) \\
 &= \frac{1}{n^2} \left( \sum_{i=1}^n EX_i^2 + 2 \binom{n}{2} (EX_i)^2 \right) \\
 &= \frac{EX_1^2 + (n-1)(EX_1)^2}{n}
 \end{aligned}$$

□

## 21.1 Metoda maximální věrohodnosti (Maximum likelihood method)

**Příklad.** Máme minci, která hází pannu s pstí  $p \in (0, 1)$ . Provedeme sérii hodů s výsledky

hody	n
panna	k

Určíme pst výsledku:  $P(\text{Při } n \text{ hodech padla } k\text{-krát panna}) = \binom{n}{k} p^k (1-p)^{n-k}$ .

Definuji si věrohodnostní funkci  $L(p) = P(\text{realizovaný výsledek experimentu})$ . Hledám  $p$  tak, aby  $L(p)$  měla co nejvyšší hodnotu.

Hledám maximum fce  $L(p) = \binom{n}{k} p^k (1-p)^{n-k}$

Můžeme zlogaritmovat (body extrémů se nezmění)

$$\log(L(p)) = \log \binom{n}{k} + k \log p + (n-k) \log(1-p)$$

$$\frac{\partial}{\partial p} \log(L(p)) = 0 + \frac{k}{p} + \frac{n-k}{1-p} \cdot (-1) = 0$$

$$\frac{k}{p} = \frac{n-k}{1-p}$$

$$k - kp = pn - pk \implies p = \frac{k}{n}$$

Najdu maximum  $L$ , potom maximálně věrohodný odhad  $\text{MLE}(p) = \text{bod maxima } L = \frac{k}{n}$

### Obecný postup pro diskrétní rozdělení

Mějme náhodný výběr s realizací  $(x_1, \dots, x_n)$ .

1. Najdeme věrohodnostní funkci

$$L(\theta) = P((X_1, \dots, X_n) = (x_1, \dots, x_n)) = \prod_{i=1}^n P(X_i = x_i) = \prod_{i=1}^n P_X(x_i)$$

2. Hledáme  $\max L(\theta)$  (obvykle přes zlogaritmování)

3. Pokud  $\theta_0$  je bod maxima  $L$ , potom  $\text{MLE}(\theta) = \theta_0$

### Obecný postup pro spojitě rozdělení

Mějme náhodný výběr s realizací  $(x_1, \dots, x_n)$ .

Jako věrohodnostní funkci bereme

$$L(\theta) = \prod_{i=1}^n f_X^\theta(x_i)$$

Jinak postup stejný jako pro diskrétní rozdělení.



## Příklady

**Příklad.** Necht'  $(x_1, x_2, \dots, x_n)$  je realizací n. výběru z rozdělení  $U[0, \alpha]$ , kde  $\alpha > 0$  je parametr. MMV odhadněte  $\alpha$ .

$$f_X(u) = \begin{cases} \frac{1}{\alpha} & u \in [0, \alpha] \\ 0 & \text{jinak} \end{cases}$$

$$L(\alpha) = \prod_{i=1}^n f_X^\theta(x_i) = \begin{cases} \left(\frac{1}{\alpha}\right)^n & (1) \alpha \geq x_i, \forall i \in \{1, \dots, n\} \\ 0 & (2) \exists i \in \{1, \dots, n\} : \alpha < x_i \end{cases}$$

Zřejmě  $L$  nebude maximální, pokud platí podmínka (2). Tedy (1) platí. Maximalizují fci  $L_1(\alpha) = \left(\frac{1}{\alpha}\right)^n$ ,  $\alpha \geq \max x_i$ .  $\left(\frac{1}{\alpha}\right)^n$  je klesající v  $\alpha \implies \max L$  se nabývá v krajním bodě def. oboru  $\implies \text{MLE}(\alpha) = \max x_i$ .

## Přednáška 22: Příklad MMV pro $Pa()$ , Odhady

29. 4. 2021

**Příklad.** Mějme výběr z  $Pa(\alpha)$  o rozsahu  $n \in \mathbb{N}$ , s realizacemi  $(x_1, \dots, x_n)$ . Odhadněte střední hodnotu tohoto rozdělení

1. Výběrový průměr

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

2. Metodou MV

$$\text{Víme } X \sim Pa(\alpha), \alpha > 1 \implies EX = \frac{\alpha}{\alpha-1}$$

$$L(\alpha) = \prod_{i=1}^n \frac{\alpha}{x_i^{\alpha+1}}$$

$$\log L(\alpha) = \sum_{i=1}^n \log \frac{\alpha}{x_i^{\alpha+1}} = \sum_{i=1}^n (\log \alpha - (\alpha + 1) \log x_i) = n \log \alpha - (\alpha + 1) \sum_{i=1}^n \log x_i$$

$$\frac{\partial}{\partial \alpha} \log(L(\alpha)) = \frac{n}{\alpha} - \sum_{i=1}^n \log(x_i) = 0$$

$$\frac{n}{\alpha} = \sum_{i=1}^n \log(x_i)$$

$$\alpha = \frac{n}{\sum_{i=1}^n \log(x_i)}$$

Kvantilová funkce

$$F_X(u) = \begin{cases} 0 \\ 1 - \frac{1}{u^\alpha} \end{cases}$$

$$\frac{1}{u^\alpha} = 1 - F_X(u)$$

$$u^\alpha = \frac{1}{1 - F_X(u)}$$

$$u = \frac{1}{(1 - F)^{1/\alpha}}$$

$$Q(u) = \frac{1}{(1 - u)^{1/\alpha}}$$

Pokus o konkrétní hodnoty Vezmeme hodnoty rovnoměrného rozdělení na  $[0, 1]$ . Poté spočteme  $Pa(1, 16)$  pomocí kvantilové funkce aplikované na hodnoty rovnoměrného rozdělení. A z těchto hodnot pak aritmetický průměr a průměr logaritmů - z něj pak střední hodnotu.

**Definice 22.1** (intervalové odhady). Nechť  $X_1, \dots, X_n$  je n. výběr z rozdělení s parametrem  $\theta$ .

Dvojice fcí (statistik)  $\{\psi_L(X_1, \dots, X_n), \psi_U(X_1, \dots, X_n)\}$  nazýváme intervalový odhad parametru  $\theta$  o spolehlivosti  $1 - \alpha$ , pokud platí že  $\forall \theta$  :

$$P_\theta(\psi_L(X_1, \dots, X_n) < \theta < \psi_U(X_1, \dots, X_n)) = 1 - \alpha$$

Intervalu  $(\psi_L(X_1, \dots, X_n), \psi_U(X_1, \dots, X_n))$  říkáme konfidenční interval.

**Definice 22.2.** Statistiky  $\psi_L(X_1, \dots, X_n)$ ,  $\psi_U(X_1, \dots, X_n)$  se nazývají dolní, resp. horní odhad parametru  $\theta$  o spolehlivosti  $1 - \alpha$ , pokud platí

$$P_\theta(\psi_L(X_1, \dots, X_n) < \theta) = 1 - \alpha,$$

resp.

$$P_\theta(\psi_U(X_1, \dots, X_n) > \theta) = 1 - \alpha.$$

Interval  $(-\infty, \psi_U(X_1, \dots, X_n))$ , resp.  $(\psi_L(X_1, \dots, X_n), \infty)$  se nazývá dolní (nebo levostranný), resp. horní (nebo pravostranný) interval spolehlivosti.

**Definice 22.3** ( $\beta$ -kvantil). Nechť distribuční funkce  $F$  je spojitá a rostoucí. Nechť  $\beta \in (0, 1)$ .

Hodnotu  $F^{-1}(\beta) = Q(\beta)$  nazveme  $\beta$ -kvantil rozdělení  $\sim F$ .  $Q$  je kvantilová funkce.

Pozn. pro  $X \sim N(0, 1)$  značíme často jako  $\beta$ -kvantil  $u_\beta$ .

Obecně značíme  $q_F(\beta)$  jako  $\beta$ -kvantil rozdělení  $F$ .

$X \sim F$

$$P(q_F(\frac{\beta}{2}) < X < q_F(1 - \frac{\beta}{2})) = F_X(q_F(1 - \frac{\beta}{2})^-) - F_X(q_F(\frac{\beta}{2})) = 1 - \frac{\beta}{2} - \frac{\beta}{2} = 1 - \beta$$

**Věta 22.4** (odhad  $\mu$  pro  $N(\mu, \sigma^2)$ ,  $\sigma^2$  známe). Nechť  $X_1, \dots, X_n$  je výběr z  $N(\mu, \sigma^2)$ , kde  $\sigma^2 > 0$  je známo.

Potom  $\{\bar{X} - u_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{X} + u_{1-\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}\}$  je intervalový odhad  $\mu$  o spolehlivosti  $1 - \alpha$ .

*Důkaz.* Platí  $X_1, \dots, X_n$  nezávislé.

Prvé odvození:  $X \sim N(\mu, \sigma^2)$

$$\frac{X - \mu}{\sigma} \sim N(0, 1)$$

$$\frac{\frac{1}{n} \sum X_i - \mu}{\frac{\sigma}{\sqrt{n}}} \sim N(0, 1)$$

(Díky nezávislosti)

$$\frac{\bar{X} - \mu}{\sigma} \cdot \sqrt{n} \sim N(0, 1)$$

$$\begin{aligned} P\left(u_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma} \cdot \sqrt{n} < u_{1-\alpha/2}\right) &= 1 - \alpha \\ P\left(\frac{u_{\alpha/2}\sigma}{\sqrt{n}} < \bar{X} - \mu < \frac{u_{1-\alpha/2}\sigma}{\sqrt{n}}\right) &= 1 - \alpha \\ P\left(\bar{X} - \frac{u_{1-\alpha/2}\sigma}{\sqrt{n}} < \mu < \bar{X} - \frac{u_{\alpha/2}\sigma}{\sqrt{n}}\right) &= 1 - \alpha \\ P\left(\bar{X} - \frac{u_{1-\alpha/2}\sigma}{\sqrt{n}} < \mu < \bar{X} + \frac{u_{1-\alpha/2}\sigma}{\sqrt{n}}\right) &= 1 - \alpha \end{aligned}$$

□

**Příklad.** Hmotnost zajíce v revíru se řídí rozdělením  $N(\mu, 2)$ . Odchylením 6 zajíců jsme naměřili hmotnosti: 4.23, 3.81, 6.15, 5.40, 4.73, 3.9

Sestrojte intervalový odhad pro průměrnou hmotnost zajíce v revíru. Pracujte se spolehlivostí 95 %.

$$X_1, \dots, X_6 \sim N(\mu, 2)$$

$$I\left(\bar{X} - u(0.975)\frac{\sigma}{\sqrt{n}}, \bar{X} + u(0.975)\frac{\sigma}{\sqrt{n}}\right)$$

Průměr z dat je 4.7,  $u(0.975) = 1.96$

$$L = 3.572, U = 5.835$$

$$\bar{X} = 4.703$$

$$I = (3.572, 5.835)$$

### Přednáška 23: Chí kvadrát, Studentovo rozdělení

5. 5. 2021

**Definice 23.1** (Funkce Gamma). Funkce  $\Gamma : \mathbb{R}^+ \rightarrow \mathbb{R}$  (Gamma) je definována následovně

$$\Gamma(a) = \int_0^\infty e^{-x} \cdot x^{a-1} dx$$

Víme (per parte):  $\Gamma(n) = (n-1)!, n \in \mathbb{N}$

**Věta 23.2** (chí-kvadrát o n stupních volnosti). Nechtě  $X_1, \dots, X_n$  jsou i. i. d,  $X_i \sim N(0, 1)$ . Potom má veličina  $Y = \sum_{i=1}^n X_i^2$  hustotu

$$g_n(t) = \frac{t^{n/2-1}}{2^{n/2} \Gamma\left(\frac{n}{2}\right)} \cdot e^{-t/2}, t > 0$$

Rozdělení  $Y$  se nazývá  $\chi_n^2$  chí-kvadrát o n stupních volnosti.

Pozn.  $EY = n, DX = 2n$

**Věta 23.3.** Nechtě  $X_1, \dots, X_n$  je n. výběr z  $N(\mu, \sigma^2)$ . Potom platí:

1.  $\bar{X}$  a  $S_n^2$  jsou nezávislé.
2.  $\frac{(n-1)}{\sigma^2} \cdot S_n^2$  má rozdělení  $\chi_{n-1}^2$ .

*Důkaz.* Důkaz v zápiscích chybí. Je v přednášce.

□

**Důsledek 23.3.1.** Necht'  $X_1, \dots, X_n$  je n. výběr z rozdělení  $N(\mu, \sigma^2)$ . Potom je interval

$$\left( \frac{(n-1)S_n^2}{q_{\chi_{n-1}^2}(1-\frac{\alpha}{2})}, \frac{(n-1)S_n^2}{q_{\chi_{n-1}^2}(\frac{\alpha}{2})} \right)$$

konfidenčním intervalem pro rozptyl  $\sigma^2$  se spolehlivostí  $1 - \alpha$ .

*Důkaz.*  $X_1, \dots, X_n \sim N(\nu, \sigma^2)$

vím:

$$\begin{aligned} P\left(q_{\chi_{n-1}^2}(\alpha/2) < \frac{(n-1)S_n^2}{\sigma^2} < q_{\chi_{n-1}^2}(1-\alpha/2)\right) &= 1 - \alpha \\ P\left(\frac{1}{q_{\chi_{n-1}^2}(1-\alpha/2)} < \frac{\sigma^2}{(n-1)S_n^2} < \frac{1}{q_{\chi_{n-1}^2}(\alpha/2)}\right) &= 1 - \alpha \\ P\left(\frac{(n-1)S_n^2}{q_{\chi_{n-1}^2}(1-\alpha/2)} < \sigma^2 < \frac{(n-1)S_n^2}{q_{\chi_{n-1}^2}(\alpha/2)}\right) &= 1 - \alpha \end{aligned}$$

□

**Věta 23.4.** Necht'  $X \sim N(0, 1)$  a  $Y_n \sim \chi_n^2$  jsou nezávislé n. v.

Potom má veličina

$$Z_n = \frac{X}{\sqrt{Y_n/n}}$$

rozdělení s hustotou

$$h_n(t) = \frac{\Gamma(\frac{n+1}{2})}{\sqrt{\pi n} \cdot \Gamma(\frac{n}{2})} \cdot \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}} = k_n \cdot \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, t \in \mathbb{R}$$

Tomuto rozdělení se říká Studentovo t-rozdělení o n stupních volnosti.

Student. t-rozdělení je symetrické kolem 0.  $EZ_n = 0$

## Přednáška 24: Studentovo t-rozdělení, testování hypotéz

6. 5. 2021

Pro vysoké hodnoty  $|t|$   $h_n(t) \sim t^{-(n+1)} \cdot c$  polynomiální pokles.

$$\left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}$$

Lze rozdělit na:

$$\left(1 + \frac{t^2}{n}\right)^{-1/2} \rightarrow 1,$$

$$\left(1 - \frac{\frac{t^2}{2}}{-\frac{n}{2}}\right)^{-n/2} \rightarrow e^{-t^2/2}$$

Celé jde k

$$e^{t^2/2}$$

Tedy pro  $n \rightarrow \infty$  platí  $t_n \rightarrow N(0, 1)$  (v distribuci).

V praxi se student. t-dist tabeluje např. do  $n = 100$ , poté se kvantily nahrazují kvantily  $N(0, 1)$ .

**Věta 24.1.** Nechť  $X_1, \dots, X_n$  je n. výběr z  $N(\mu, \sigma^2)$ .  $\sigma^2 > 0$ . Potom má veličina

$$T = \frac{\bar{X} - \mu}{S_n} \sqrt{n}$$

Studentovo t-rozdělení o  $(n - 1)$  stupních volnosti.

*Důkaz.* Víme  $X' \sim N(0, 1)$ ,  $Y_n \sim X_n^2$  nezávislé.

Potom

$$\frac{X'}{\sqrt{\frac{Y_n}{n}}} \sim t_n$$

$$X' = \frac{\bar{X} - \mu}{\sigma} \sqrt{n} \dots \text{opravdu má } N(0, 1)$$

$$Y = \frac{S_n^2(n-1)}{\sigma^2} \dots \text{odpovídá } \chi_{n-1}^2$$

$X', Y$  nezávislé, neboť  $\bar{X}$  a  $S_n^2$  jsou nezávislé.

$$t_{n-1} \sim \frac{X'}{\sqrt{\frac{Y}{n-1}}} = \frac{\frac{\bar{X} - \mu}{\sigma} \sqrt{n}}{\sqrt{\frac{S_n^2(n-1)}{\sigma^2(n-1)}}} = \frac{\bar{X} - \mu}{S_n} \sqrt{n} = T$$

□

**Důsledek 24.1.1.** Nechť  $X_1, \dots, X_n$  je n. výběr z  $N(\mu, \sigma^2)$ , kde ani jeden z parametrů není znám. Potom

$$\left\{ \bar{X} - q_{t_{n-1}} \left( 1 - \frac{\alpha}{2} \right) \cdot \frac{S_n}{\sqrt{n}}, \bar{X} + q_{t_{n-1}} \left( 1 - \frac{\alpha}{2} \right) \cdot \frac{S_n}{\sqrt{n}} \right\}$$

je int. odhad  $\mu$  o spolehlivosti  $1 - \alpha$ .

*Důkaz.* Ze symetrie t-rozdělení platí  $q_{t_{n-1}}(\alpha/2) = -q_{t_{n-1}}(1 - \frac{\alpha}{2})$ .

Platí

$$\begin{aligned} P(q_{t_{n-1}}(\alpha/2) < T < q_{t_{n-1}}(1 - \alpha/2)) &= 1 - \alpha \\ P\left(-q_{t_{n-1}}(1 - \frac{\alpha}{2}) \cdot \frac{S_n}{\sqrt{n}} < \bar{X} - \mu < q_{t_{n-1}}(1 - \frac{\alpha}{2}) \cdot \frac{S_n}{\sqrt{n}}\right) &= 1 - \alpha \\ P\left(\bar{X} - q_{t_{n-1}} \left( 1 - \frac{\alpha}{2} \right) \frac{S_n}{\sqrt{n}} < \mu < \bar{X} + q_{t_{n-1}} \left( 1 - \frac{\alpha}{2} \right) \cdot \frac{S_n}{\sqrt{n}}\right) &= 1 - \alpha \end{aligned}$$

□

## 24.1 Testování hypotéz

Máme výběr  $X_1, \dots, X_n$  z rozdělení  $F$  s parametrem  $\theta$  a chceme otestovat dvě proti sobě jdoucí hypotézy o  $\theta$ .

1.  $\theta \in \Omega_0$ ,
2.  $\theta \in \Omega_1$ ,

$$\Omega_0 \cap \Omega_1 = \emptyset$$

Typicky si stanovíme tzv. nulovou hypotézu  $H_0 : \theta \in \Omega_0$  a tzv. alternativní hypotézu  $H_1 : \theta \in \Omega_1$ . Obvykle  $\Omega_1 = \bar{\Omega}_0$ .

Testem nulové hypotézy proti alternativní rozumíme rozhodovací proces založený na realizaci výběru  $x_1, \dots, x_n$ , na jehož základě zamítneme nebo nezamítneme  $H_0$ . (Když zamítneme  $H_0$ , je to ve prospěch  $H_1$ .)

### Možné 4 výsledky

1. platí  $H_0$  a my nezamítáme  $H_0$ .
2. zamítneme  $H_0$  i když  $H_0$  platí. To je chyba 1. druhu.
3. nezamítneme  $H_0$ , ale  $H_0$  neplatí. To je chyba 2. druhu.
4. zamítneme  $H_0$  a  $H_0$  neplatí.

V praxi chceme kontrolovat chybu 1. druhu (čili  $\leq \alpha$ ) za těchto podmínek minimalizovat chybu 2. druhu.

$\alpha$  se nazývá hladina významnosti testu.

Postupujeme tak, že v závislosti na  $\alpha$  stanovíme tzv. kritický obor  $W \subseteq \mathbb{R}^n$ , což je množina, pro kterou platí  $(x_1, \dots, x_n) \in W$ , potom  $H_0$  zamítáme. (Kritický obor)

Pro  $W$  platí  $P_\theta((X_1, \dots, X_n) \in W) \leq \alpha, \forall \theta \in \Omega_0$ . Dále chceme, aby  $P_\theta((X_1, \dots, X_n) \notin W), \theta \in \Omega_1$  bylo minimální.

**Příklad.** Máme výběr z  $N(\mu, 1)$  a chceme testovat  $\mu = \mu_0$  (pro jisté dané  $\mu_0$ ) proti  $\mu > \mu_0$ , na hladině významnosti  $\alpha$ .

Tedy:  $H_0 : \mu = \mu_0, H_1 : \mu > \mu_0$

Sestavíme testovací statistiku

$$U = \frac{\bar{X} - \mu}{\sigma} \sqrt{n} = \frac{\bar{X} - \mu}{1} \sqrt{n}$$

Pokud platí  $H_0$ , potom  $U \sim N(0, 1)$

Hodnotu  $U(x_1, \dots, x_n) > u_{1-\alpha}$ , potom zamítám  $H_0$ .

Pokud platí  $H_0$  (tj.  $\mu = \mu_0$ , potom  $P(\text{zamítáme } H_0) = \alpha$ . Kritický obor je roven  $W\{(x_1, \dots, x_n) \in \mathbb{R}^n | U(x_1, \dots, x_n) > u_{1-\alpha}\}$

**Příklad.** Odpor rezistoru je n. veličina s rozdělením  $N(\mu, 0.01)$  v Ohmech. Provedli jsme 5 měření, jejichž hodnoty byly: 3.1, 2.95, 3.23, 3.01, 2.98.

Testujte na hladině  $\alpha = 0.05$ , že průměrný odpor rezistoru je roven  $3\Omega$ .

Hypotézy:  $H_0 : \mu = 3, H_1 : \mu \neq 3$

Za platnosti  $H_0$  má veličina

$$U = \frac{\bar{X} - \mu_0}{\sigma} \sqrt{n} = \frac{\bar{X} - 3}{0.1} \sqrt{5}$$

rozdělení  $N(0, 1)$ . Dosadím hodnoty realizací.

$$\bar{X} = \frac{15.27}{5} = 3.054,$$

$$U = \frac{0.054}{0.1} \sqrt{5} = 0.54 \sqrt{5} = 1.207.$$

$$u_{0.95} = 1.64$$

Na základě naměřených dat na hladině významnosti 0.05 nelze zamítnout  $H_0$ .



## 25.1 Testy normálního rozdělení

Situace: Máme výběr  $X_1, \dots, X_n$  z rozdělení  $N(\mu, \sigma^2)$ .

1. Chceme testovat  $\mu = \mu_0$  a je známa hodnota  $\sigma^2 > 0$ . (Test střední hodnoty n. rozdělení při známém rozptylu  $\mu_0$  je předem stanovená.)

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0 \text{ (oboustranný test)}$$

případně  $\mu > \mu_0$  nebo  $\mu < \mu_0$

Statistika

$$U = \frac{\bar{X} - \mu_0}{\sigma} \sqrt{n} \text{ má za platnosti } H_0 \text{ rozdělení } N(0, 1)$$

Z toho vyplývá, že kritický obor pro test na hladině  $\alpha$ :

Pro oboustrannou variantu

$$W_\alpha = \{x \in \mathbb{R}^n \mid |U(x)| > u_{1-\frac{\alpha}{2}}\}$$

Pro  $H_1 : \mu > \mu_0$

$$W_\alpha = \{x \in \mathbb{R}^n \mid U(x) > u_{1-\alpha}\}$$

Pro  $H_1 : \mu < \mu_0$

$$W_\alpha = \{x \in \mathbb{R}^n \mid U(x) < -u_{1-\alpha}\}$$

2. Chceme testovat  $\sigma^2$  při neznámých parametrech  $\mu, \sigma^2 > 0$

$$H_0 : \sigma = \sigma_0, \text{ pro dané } \sigma_0$$

$$H_1 : \sigma \neq \sigma_0$$

případně  $\sigma > \sigma_0, \sigma < \sigma_0$

Za platnosti  $H_0$  má veličina  $Y$

$$Y = \frac{S_n^2(n-1)}{\sigma_0^2} \text{ rozdělení } \chi_{n-1}^2$$

Pro oboustrannou variantu

$$W_\alpha = \{x \in \mathbb{R}^n \mid Y(x) < q_{\chi_{n-1}^2}(\alpha/2) \vee Y(x) > q_{\chi_{n-1}^2}\left(1 - \frac{\alpha}{2}\right)\}$$

Pro jednostrannou variantu  $\sigma > \sigma_0$

$$W_\alpha = \{x \in \mathbb{R}^n \mid Y(x) > q_{\chi_{n-1}^2}(1 - \alpha)\}$$

Analogicky  $\sigma < \sigma_0$

3. Chceme testovat  $\mu$  a neznáme  $\sigma^2 > 0$  (test střední hodnoty normálního rozdělení s neznámým rozptylem)

Tento test se nazývá (jednovýběrový) T-test.

$$H_0 : \mu = \mu_0$$

$$H_1 : \mu \neq \mu_0$$

případně  $\mu > \mu_0$  nebo  $\mu < \mu_0$

Za platnosti  $H_0$  má veličina

$$T = \frac{\bar{X} - \mu_0}{S_n} \sqrt{n} \text{ Studentovo t-rozdělení s } n-1 \text{ stupni volnosti}$$

Pro oboustrannou variantu

$$W_\alpha = \{x \in \mathbb{R}^n \mid |T(x)| > q_{t_{n-1}} \left(1 - \frac{\alpha}{2}\right)\}$$

Pro jednostrannou variantu  $\mu > \mu_0$

$$W_\alpha = \{x \in \mathbb{R}^n \mid T(x) > q_{t_{n-1}}(1 - \alpha)\}$$

pro  $\mu < \mu_0$  analogicky

## 25.2 Párový T-test

Situace: máme výběr  $(Y_1, Z_1), \dots, (Y_n, Z_n)$  z nějakého dvourozměrného rozdělení se střední hodnotou  $(\mu_1, \mu_2) \in \mathbb{R}^2$ . Předpokládejme  $Y_i - Z_i \sim N(\mu_1 - \mu_2, \sigma^2)$ ,  $\sigma^2 > 0$ . Chceme testovat

$$H_0 : \mu_1 - \mu_2 = k \text{ pro předem dané } k \in \mathbb{R} \text{ (často } k = 0)$$

$$H_1 : \mu_1 - \mu_2 \neq k$$

pozn. v praxi bývají  $Y, Z$  závislé, často 2 atributy jednoho objektu.

Převédeme na jednovýběrový T-test

$$X_i = Y_i - Z_i \sim N(\mu_1 - \mu_2, \sigma^2)$$

Z toho plyne  $X_1, \dots, X_n$  je výběr z  $N(\mu_1 - \mu_2, \sigma^2)$ , kde parametry nejsou známy.

$$H_0 : EX_1 = k$$

$$H_1 : EX_1 \neq k$$

$$W_\alpha = \{x \in \mathbb{R}^n \mid |T(x)| > q_{t_{n-1}} \left(1 - \frac{\alpha}{2}\right)\}$$

**Příklad.** Má se rozhodnout, zda se u osobního automobilu určité značky i typu při správném seřízení geometrie vozu sjíždějí obě přední pneu stejně rychle. Bylo vybráno 6 nových vozů a po určité době bylo zjištěno, o kolik mm se sjely pravé a levé přední pneumatiky

vozidlo	1	2	3	4	5	6
L	1.8	1.0	2.2	0.9	1.5	1.6
P	1.5	1.1	2.0	1.4	1.4	1.4
rozdíl	0.3	-0.1	0.2	-0.2	0.1	0.2

$$\alpha = 0.05$$

$$X = L - P$$

$$X_i \sim N(\mu, \sigma^2)$$

$$T = \frac{\bar{X} - 0}{S_n} \sqrt{n} \sim t_{n-1}$$

Hypotézu, že  $H_0$  : pneu se sjíždějí průměrně stejně  $H_1 : \neg H_0$

$H_0$  zamítne, pokud  $|T| > q_{t_5} \left(1 - \frac{\alpha}{2}\right)$

$$\bar{X} = 0.0833$$

$$S^2 = 0.0377$$

$$T = 1.0518$$

$$q_{t_5}(0.975) = 2.571$$

To znamená, že nelze zamítnout hypotézu o tom, že se pravá a levá pneu sjíždějí stejně.

**Věta 25.1.** Necht'  $(X_1, \dots, X_n)$  je výběr z  $N(\mu_1, \sigma^2)$ ,  $\sigma > 0$  a  $Y_1, \dots, Y_m$  je výběr z  $N(\mu_2, \sigma^2)$ . Necht' jsou tyto výběry nezávislé.

Potom má veličina

$$T = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{S_X^2(n-1)S_Y^2(m-1)}} \sqrt{\frac{(n+m-2)nm}{n+m}}$$

rozdělení  $t_{n+m-2}$

*Důkaz.* (Náznak)

víme  $W \sim N(0, 1)$ ,  $Z \sim \chi_n^2$

Z toho

$$\frac{W}{\sqrt{\frac{Z}{n}}} \sim t_n$$

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma^2}{n} + \frac{\sigma^2}{m}}} \sim N(0, 1) \quad (1)$$

$$\frac{X_X^2(n-1)}{\sigma^2} \sim \chi_{n-1}^2, \frac{S_Y^2(m-1)}{\sigma^2} \sim \chi_{m-1}^2$$

$$\frac{S_X^2(n-1) + S_Y^2(m-1)}{\sigma^2} \sim \chi_{n+m-2}^2 \quad (2)$$

Dáme dohromady (1) a (2)

$$\frac{\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sigma^2 \left( \frac{m+n}{mn} \right)}}{\sqrt{\frac{S_X^2(n-1) + S_Y^2(m-1)}{\sigma^2(n+m-2)}}}$$

Což nám dá veličinu T z věty. □

## Přednáška 26: Statistické testy

19. 5. 2021

### 26.1 Dvouvýběrový T-test

situace: Máme výběr  $(X_1, \dots, X_n)$  z  $N(\mu_1, \sigma^2)$ ,  $n \in \mathbb{N}$  a výběr  $(Y_1, \dots, Y_m)$ ,  $m \in \mathbb{N}$ .

Tyto výběry (předpokládáme) jsou nezávislé.

Chceme testovat shodnost středních hodnot za předpokladu shody rozptylů.

$H_0 : \mu_1 - \mu_2 = c$  (často volíme  $c = 0$ .) (případně jednostranné varianty.)

Pokud platí  $H_0$ , potom T

$$T = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{(m-1)S_Y^2 + (n-1)S_X^2}} \sqrt{\frac{mn(m+n-2)}{m+n}}$$

kritický obor:

$$W_\alpha = \{(x, y) \in \mathbb{R}^n \times \mathbb{R}^m \mid T(X, Y) > q_{t_{m+n-2}} \left(1 - \frac{\alpha}{2}\right)\}$$

**Příklad.** Máme dvě naleziště zlata. Stejnou metodou zpracováváme rudu. Chceme zjistit, na kterém nalezišti je výhodnější pracovat, máme-li omezené zdroje. Máme data (g zlata na kilogram rudy) k oběma nalezištím (6 vzorků z A, 8 vzorků z B)

A ... 16.1, 18.3, 12, 17.6, 23.4, 20.2

B ... 14.8, 16.2, 24.6, 20.4, 19.8, 16.6, 17.7, 15.3

$$X_1, \dots, X_6 \sim N(\mu_1, \sigma^2)$$

$$Y_1, \dots, Y_8 \sim N(\mu_2, \sigma^2)$$

$$\bar{X} = 17.93$$

$$\bar{Y} = 18.05$$

$$S_X^2 = 12.3$$

$$S_Y^2 = 10$$

$$H_0 : \mu_1 = \mu_2$$

$$H_1 : \mu_1 \neq \mu_2$$

Za předpokladu  $H_0$  má statistika

$$T = \frac{\bar{X} - \bar{Y}}{\sqrt{7 \cdot S_Y^2 + 5 \cdot S_X^2}} \sqrt{\frac{48(6 + 8 - 2)}{6 + 8}}$$

Studentovo t-rozdělení.

$$T = \frac{-0.12}{\sqrt{131.5}} \sqrt{\frac{288}{7}} = -0.067$$

$$|T| = 0.067 < q_{t_{1/2}}(0.975)$$

Na hladině 0.05 nelze zamítnout hypotézu o tom, že obě naleziště jsou stejně výnosná v obsahu zlata na kilogram rudy.

### Párový T-test vs. dvouvýběrový T-test

Párový T-test

- rozsahy výběru jsou stejné
- výběry nejsou nezávislé, naopak jde o 2 atributy jednoho objektu

Dvouvýběrový T-test

- rozsahy výběrů se můžou lišit
- výběry jsou nezávislé

## 26.2 Test shodnosti rozptylů (norm. rozdělení)

Máme 2 nezávislé výběry  $X_1, \dots, X_n$  z  $N(\mu_1, \sigma_1^2)$ ,  $Y_1, \dots, Y_m$  z  $N(\mu_2, \sigma_2^2)$

chceme testovat  $H_0 : \sigma_1 = \sigma_2$

$$H_1 : \sigma_1 \neq \sigma_2$$

Za platnosti  $H_0$  má statistika

$$F = \frac{S_X^2}{S_Y^2}$$

rozdělení F (Fisherovo) o  $(n - 1)$  a  $(m - 1)$  stupních volnosti.

V praxi za  $X_1, \dots, X_n$  volím ten výběr s  $S_X^2 > S_Y^2$ . Potom pokud  $F > q_{F_{n-1, m-1}}$ , potom zamítáme  $H_0(1 - \alpha)$

### Fisherovo rozdělení

$X \sim \chi_n^2$ , X, Y nezávislé

$Y \sim \chi_m^2$

Potom

$$Z = \frac{\frac{X}{n}}{\frac{Y}{m}}$$

má rozdělení F (Fisherovo) o n, m stupních volnosti.

## 26.3 Test homogenity 2 binomických rozdělení

Máme dva nezávislé výběry z  $Alt(p_1)$  a z  $Alt(p_2)$ . Čili  $X_1, \dots, X_n \sim Alt(p_1)$ .  $Y_1, \dots, Y_m \sim Alt(p_2)$

$$X = \sum_{i=1}^n X_i \sim Bi(n, p_1)$$

$$Y = \sum_{i=1}^m Y_i \sim Bi(m, p_2)$$

$H_0 : p_1 = p_2$

$H_1 : p_1 \neq p_2$

$$x = \frac{X}{n} \dots \text{odhad } p_1$$

$$y = \frac{Y}{m} \dots \text{odhad } p_2$$

$$X \sim N(np_1, np_1(1 - p_1)), Y \sim N(mp_2, mp_2(1 - p_2))$$

$$Ex = p_1, Ey = p_2$$

$$Dx = \frac{p_1(1-p_1)}{n}, Dy = \frac{p_2(1-p_2)}{m}$$

$$z = \frac{X+Y}{n+m}$$

$$U_1 = \frac{x-y}{\sqrt{\frac{x(1-x)}{n} + \frac{y(1-y)}{m}}} \sim N(0,1), \text{ pokud platí } H_0$$

$$U_2 = \frac{x-y}{\sqrt{\frac{z(1-z)}{m+n}}} \sim N(0,1), \text{ pokud platí } H_0$$

$H_0$  zamítáme, pokud  $|U_1| > u_{1-\frac{\alpha}{2}}$ , v případě prvního testu.

$H_0$  zamítáme, pokud  $|U_2| > u_{1-\frac{\alpha}{2}}$ , v případě druhého testu.

## Přednáška 27: Chí kvadrát testy, testy dobré shody

20. 5. 2021

**Definice 27.1.** Máme  $k \in \mathbb{N}$ ,  $k \geq 2$  navzájem se vylučujících jevů.

$A_1, \dots, A_k$ , pro které platí  $P(\cup_{i=1}^k A_i) = 1$

Označme jejich psti  $P(A_i) = p_i$  (tedy  $\sum_{i=1}^k p_i = 1$ )

Provádíme experiment, u kterého jsou možné pouze výsledky  $A_1, \dots, A_k$ , experiment  $n$ -krát opakujeme.

Tedy výsledky testu lze zapsat do tabulky

	$A_1$	$A_2$	$\dots$	$A_k$	celkem
četnost jevu	$l_1$	$l_2$	$\dots$	$l_k$	$n$

Rozdělení s parametry  $n, p_1, p_2, \dots, p_k$  nazýváme multinomické.

Formálně lze říci, že  $X \sim \text{Multi}(n, p_1, \dots, p_k)$ , pokud  $X = (X_1, \dots, X_k)$  je  $n$ . vektor  $X_i \in \{0, \dots, n\}$

$$\sum_{i=1}^k X_i = n$$

Pstní fce vektoru  $X$  s  $\text{Multi}(n, p_1, \dots, p_k)$  je rovna

$$p_X(a_1, \dots, a_k) = P(X_1 = a_1, X_2 = a_2, \dots, X_k = a_k) = \frac{n!}{a_1! \cdot a_2! \cdot \dots \cdot a_k!} p_1^{a_1} \cdot \dots \cdot p_k^{a_k},$$

pro  $a = (a_1, \dots, a_k) \in \{0, \dots, n\}^k$

**Příklad.**  $n$ -krát hodíme kostkou. Vektor  $X = (X_1, \dots, X_6)$  označující počty jedniček,  $\dots$ , šestek má multinomické rozdělení o rozsahu  $n$  a psti  $p_1 = p_2 = \dots = p_6 = \frac{1}{2}$

$$X \sim \text{Multi}\left(n, \frac{1}{6}, \dots, \frac{1}{6}\right)$$

**Poznámka.** pro  $k = 2$  máme  $A_1 = \overline{A_2}$

$$\Rightarrow p_X(a_1, n - a_1) = \frac{n!}{a_1! \cdot (n - a_1)!} p_1^{a_1} (1 - p_1)^{n - a_1} = \binom{n}{a_1} \cdot p_1^{a_1} (1 - p_1)^{n - a_1}$$

$\Rightarrow$  pro  $k = 2$  jde o binomické rozdělení

## 27.1 Test parametrů multinomického rozdělení

Máme experiment, jehož výsledek lze chápat jako  $n$ . vektor  $X = (X_1, \dots, X_k) \sim \text{Mult}(n, p_1, \dots, p_k)$ , kde  $p_i > 0, \forall i \in \{1, \dots, k\}$

Chceme testovat, jestli  $p_1 = p_1^0, \dots, p_k = p_k^0$  pro jistý vektor pstí  $p_1^0, \dots, p_k^0$

$$H_0 : \forall i \in \{1, \dots, k\} : p_i = p_i^0$$

$$H_1 : \forall i \in \{1, \dots, k\} : p_i \neq p_i^0$$

Testování statistiky

$$\chi^2 = \sum_{i=1}^k \frac{X_i - n \cdot p_i^0}{n \cdot p_i^0}$$

má za platnosti  $H_0$  rozdělení  $\chi_{k-1}^2$ . Hypotézu  $H_0$  zamítáme, pokud  $\chi^2 > q_{\chi_{k-1}^2}(1 - \alpha)$ .

$np_i^0$  jsou teoretické četnosti

$X_i$  jsou pozorované četnosti

**Příklad.** Chceme testovat, jestli kostka je symetrická/hází férově. Provedeme 600 hodů, jejichž souhrnné výsledky jsou v tabulce.

číslo	1	2	3	4	5	6	celkem
četnost	96	91	107	102	93	111	600
$p_i$	1/6	1/6	1/6	1/6	1/6	1/6	1
teoretické četnosti $np_i$	100	100	100	100	100	100	600
$\chi^2$	16/100	81/100	49/100	4/100	49/100	121/100	

$H_0$  : kostka je férová (tj.  $p_i = 1/6, \forall i \in \{1, \dots, 6\}$ )

$H_1 : \neg H_0$

$X_i \dots O_i$  observed



$np_i \dots E_i$  expected

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}$$

$$\chi^2 = \sum_{i=1}^k \frac{(X_i - np_i)^2}{np_i} = \sum_{i=1}^6 \frac{(X_i - 100)^2}{100} = \frac{320}{100} = 3.2 < 11.1 = q_{\chi^2_5}(0.95)$$

Nelze na hladině  $\alpha = 0.05$  zamítnout hypotézu o tom, že je kostka symetrická.

**Příklad.** V jisté oblasti zkoumáme výskyt daného dravce. Oblast jsme rozdělili na nestejně velké části. Tabulka uvádí počty pozorovaných dravců v oblastech. Testujte, zda se dravec preferuje nějakou konkrétní oblast.

oblast	A	B	C	D	celkem
rozlohy	47 km <sup>2</sup>	91 km <sup>2</sup>	32 km <sup>2</sup>	80 km <sup>2</sup>	250 km <sup>2</sup>
počet výskytů	4	7	5	12	25
$p_i$	47/250	91/250	32/250	80/250	
$np_i$	4.7	9.1	3.2	8	

$$\chi^2 = \sum_{i=1}^4 \frac{(np_i - X_i)^2}{np_i} = \frac{1.7^2}{4.7} + \frac{2.1^2}{9.1} + \frac{0.8^2}{3.2} + \frac{3^2}{8} = 2.43$$

Na hladině  $\alpha = 0.05$  nelze zamítnout hypotézu o tom, že výskyt dravce v regionu je rovnoměrný.